

UNIVERSIDAD DE INGENIERÍA Y TECNOLOGÍA

CARRERA DE CIENCIAS DE LA COMPUTACIÓN



**Evaluación de funciones de comparación entre
distribuciones de grafos bajo perturbaciones
controladas**

TRABAJO DE INVESTIGACIÓN

Para optar el grado de licenciado en CIENCIAS DE LA
COMPUTACIÓN

AUTOR(ES)

Dimael Antonio Rivas Chavez 

ASESOR(ES)

Ariana Mirella Villegas Suarez 

Lima - Perú

2026

Dedicatoria:

[illegible]

Agradecimientos:

[illegible]

TABLA DE CONTENIDO

	Pág.
RESUMEN	1
ABSTRACT	2
INTRODUCCIÓN	3
Presentación del tema de investigación	3
Descripción de la situación problemática	4
Formulación del problema	6
Objetivos de investigación	8
Justificación	10
Alcance y limitaciones	11
 CAPÍTULO I REVISIÓN CRÍTICA DE LA LITERATURA	 14
1.1 De la evaluación de grafos generados a la comparación de distribuciones de grafos	14
1.2 Distribuciones de grafos, representaciones y riesgo de agregación	15
1.3 MMD con descriptores estructurales como línea base	17
1.4 Métodos espectrales y comparación multiescala	18
1.5 Weisfeiler–Lehman y Wasserstein–Weisfeiler–Lehman	20
1.6 Modelos sintéticos y estructura controlable	21
1.7 Comunidades reales, comunidades generativas y pseudo-etiquetas	22
1.8 Perturbaciones estructurales e intensidad de cambio	23
1.9 Criterios críticos de comparación entre métricas	24

1.10 Síntesis crítica y brecha de investigación	26
---	----

CAPÍTULO II MARCO TEÓRICO 27

2.1 Comparación de grafos como problema computacional	27
2.2 Comparación de distribuciones de grafos	28
2.3 Escalas estructurales en grafos	30
2.4 Métodos basados en estadísticas estructurales y MMD	30
2.5 Kernels de grafos y Weisfeiler–Lehman	32
2.6 Transporte óptimo y Wasserstein–Weisfeiler–Lehman	32
2.7 Representaciones espectrales y NetLSD	33
2.8 Representaciones multiescala y coarsening	34
2.9 Modelos sintéticos de grafos	35
2.9.1 Erdős–Rényi	35
2.9.2 Stochastic Block Model	35
2.9.3 Barabási–Albert	35
2.9.4 Watts–Strogatz	36
2.9.5 Grid	36
2.9.6 Lobster	36
2.10 Comunidades, modularidad y pseudo-etiquetas	36
2.11 Perturbaciones controladas	37
2.12 Análisis pareado e inferencia estadística	38
2.13 Criterios de evaluación de métodos	39

CAPÍTULO III MARCO REFERENCIAL (LEGAL, GEOGRÁFICO, HISTÓRICO) (opcional) 40

3.1 Primer subtítulo	40
--------------------------------	----

CAPÍTULO IV MARCO METODOLÓGICO 41

4.1 Diseño general de la investigación	42
4.2 Pregunta metodológica	43

4.3 Selección de workflows de comparación	44
4.4 Datasets y distribuciones base	46
4.4.1 Distribuciones sintéticas	46
4.4.2 Dataset real	47
4.5 Tratamiento de comunidades	48
4.6 Operadores de perturbación controlada	49
4.6.1 Perturbaciones locales	50
4.6.2 Perturbaciones mesoscópicas	51
4.6.3 Perturbaciones globales	51
4.6.4 Perturbaciones mixtas	52
4.6.5 Perturbaciones distribucionales	52
4.7 Protocolo experimental	52
4.8 Niveles de medición y criterios de evaluación	54
4.8.1 Discrepancia distribucional	54
4.8.2 Cambio promedio de representación	54
4.8.3 Distancia pareada individual	55
4.8.4 Distancia pareada agregada	56
4.8.5 Sensibilidad	56
4.8.6 Correlación entre intensidad y puntaje	57
4.8.7 Monotonicidad como criterio de consistencia	58
4.8.8 Pruebas estadísticas sobre diferencias pareadas	58
4.8.9 Robustez	59
4.8.10 Costo computacional	59
4.8.11 Interpretabilidad y análisis de casos discordantes	60
4.9 Organización de resultados por tipo de perturbación	61
4.10 Reproducibilidad	62
4.11 Limitaciones metodológicas	63
4.12 Cierre del marco metodológico	64

CAPÍTULO V RESULTADOS PRELIMINARES	65
5.1 Descripción general del experimento preliminar	65
5.2 Figuras utilizadas en el análisis preliminar	67
5.3 Resultados agregados por workflow	70
5.3.1 Rango de respuesta frente a magnitud de respuesta	70
5.3.2 Síntesis cualitativa	71
5.4 Resultados en perturbaciones locales	73
5.5 Resultados en perturbaciones mesoscópicas	74
5.6 Resultados en perturbaciones globales	75
5.7 Perturbaciones no evaluadas en esta etapa	76
5.8 Relación con las hipótesis metodológicas	77
5.9 Limitaciones de los resultados preliminares	77
5.10 Validaciones pendientes	78
5.11 Síntesis preliminar	79
CONCLUSIONES	80
RECOMENDACIONES	81
ANEXOS	85

ÍNDICE DE TABLAS

Tabla 4.1	Función metodológica de las distribuciones sintéticas consideradas.	47
Tabla 4.2	Dataset real considerado en la evaluación.	48
Tabla 5.1	Magnitud máxima del puntaje distribucional crudo por workflow en la corrida consolidada. Las magnitudes no son directamente comparables entre familias, ya que corresponden a construcciones distintas (un estadístico MMD frente a distancias L_2 entre representaciones); se reportan para evidenciar la escala de respuesta dentro de cada workflow, no para inducir un ordenamiento de superioridad. . .	71
Tabla 5.2	Resumen comparativo de los workflows evaluados	72

ÍNDICE DE FIGURAS

Figura 4.1	Pipeline metodológico para la evaluación de funciones de comparación entre distribuciones de grafos bajo perturbaciones controladas.	43
Figura 5.1	Puntaje <i>normalizado por workflow</i> de discrepancia distribucional en función de la intensidad de perturbación α . La figura compara la forma de la respuesta de cada workflow frente al incremento progresivo de perturbación; no representa magnitudes absolutas comparables entre workflows (véase la Tabla 5.1).	68
Figura 5.2	Distancia pareada <i>promedio</i> (P_α , normalizada por workflow) entre cada grafo original y su versión perturbada. Esta figura complementa el análisis agregado, ya que aprovecha la correspondencia inducida por el protocolo experimental; corresponde al promedio por celda y no a las distancias individuales $p_{i,\alpha}$.	69
Figura 5.3	Mapa de sensibilidad por granularidad estructural, entendida aquí como la correlación ordinal entre α y el puntaje (consistencia direccional). La figura resume el comportamiento relativo de los workflows frente a perturbaciones locales, mesoscópicas y globales; la cercanía entre workflows indica similitud de rango y no de magnitud de respuesta.	70

RESUMEN

Lorem ipsum dolor sit amet, cum tollit aeterno ut. Sea amet iuvaret placerat in, saperet impedit consulatu mei ne, quo no alii vituperatoribus. No mutat dolorum habemus pro, vis rebum accusam no, meis partiendo necessitatibus cu sit. Zril mediocrem scriptorem cu quo, ex duo mucius doming legendos. Posse nemore cu cum. Et facer pertinax sed, atqui ignota antiopam in pro, dolore oportere ius ex.

An justo nonumy mnesarchum quo, eruditi cotidieque in sed. Consulatu urbanitas conceptam eam id, liber accusamus eu mel. Ius iusto albucius elaboraret id, dico partiendo contentiones nec in, sint eruditi per ne. No eruditi probatus cum, no mei sumo facer torquatos. Sea dicunt facilisis corrumpit at, audiam accusam eligendi qui ne.

Facete officiis invenire sit ex, facete causae fabellas ei qui. Et pertinacia contentiones definitiones nam. Cum moderatius signiferumque in, blandit senserit cum no. Mea appareat posidonium contentiones an, no case accommodare cum, ei sea oporteat percipitur. Ea congrue necessitatibus sed, no adhuc graeco usu. Eam harum equidem fierent ne, duo id facer consequuntur signiferumque. Dolore molestie phaedrum nec ei, ei eos noluisse constituto. Eruditi propriae in mea, vero laboramus cotidieque ad duo. Tacimates constituto est ex, ad mei clita sapientem evertitur.

Palabras clave:

Palabra clave 1; Palabra clave 2; Palabra clave 3; Palabra clave 4

ABSTRACT

TÍTULO DE LA TESIS EN INGLÉS

Lorem ipsum dolor sit amet, with the eternal God, that takes away the. Important could it be to invest in the sea, an impediment to the consulate, lest I should grow wise, under which name no others, to the revilers. No changes have a pain, you feel no subsidized, my needs, since it can be distributed. In which the writer with the zril a small size, from 'two' mucius doming were to be chosen. A man can do with him. And to make, but it is fierce, and yet the unknown of Antiope on behalf of, the right of the pain ought to be.

Is this just mnesarchum running smoothly, but instructed the daily. Consulate refinement to this concept, a book accusing football honey. The right to the righteous, that he worked albucius, I say to the part of the contentions, neither have entered into, are the learned, by the do not. No approved as instructed, no curling but do take me. Antioxidants dough at sea say, I feel they should be chosen.

Elegantly offices to find out, salty stories to the cause. For definitions and resolution of conflicts. When measured signiferumque to sit when he feels no. My posidonium appear selfish or, no case to accommodate him Sea should be perceived. Planning needs but that no further Greek practice. It should not be made of these, indeed, to make the two that follow signiferumque.

Keywords:

Keyword 1; Keyword 2; Keyword 3; Keyword 4

INTRODUCCIÓN

Presentación del tema de investigación

La comparación entre distribuciones de grafos constituye un problema relevante en Ciencias de la Computación, especialmente en aprendizaje automático sobre estructuras discretas, evaluación de modelos generativos, detección de cambio distribucional y análisis de robustez topológica. A diferencia de la comparación entre grafos individuales, este problema no busca determinar si dos grafos particulares son similares, sino evaluar si dos poblaciones de grafos presentan diferencias estructurales sistemáticas.

Sea $\mathcal{G}$ el espacio de grafos simples, no dirigidos y finitos, considerados salvo isomorfismo. Una distribución de grafos puede entenderse como una medida de probabilidad $\mathcal{P}$ sobre $\mathcal{G}$. En la práctica, dicha distribución no se observa directamente, sino mediante una muestra finita:

$$S = \{G_1, G_2, \dots, G_n\}, \quad G_i \sim \mathcal{P}.$$

El presente trabajo estudia cómo distintas familias de funciones de comparación responden cuando una distribución base de grafos es sometida a perturbaciones estructurales controladas. Para ello, se considera una familia de operadores de perturbación $\mathcal{T}_\alpha$, donde $\alpha \in [0, 1]$ representa la intensidad de la perturbación. La distribución perturbada se denota como:

$$\mathcal{P}_\alpha = \mathcal{T}_\alpha(\mathcal{P}).$$

A partir de esta formulación, el interés central no consiste únicamente en calcular una distancia entre $\mathcal{P}$ y $\mathcal{P}_\alpha$, sino en caracterizar cómo cambia dicha distancia cuando la perturbación aumenta progresivamente. Es decir, se busca analizar el comportamiento empírico de una función de comparación D :

$$d_D(\alpha) = D(\mathcal{P}, \mathcal{P}_\alpha).$$

La investigación se concentra en familias metodológicas representativas para la comparación de distribuciones de grafos: métodos basados en Maximum Mean Discrepancy con descriptores estructurales, métodos espectrales o multiescala basados en firmas laplacianas como NetLSD, y métodos basados en Weisfeiler–Lehman, Wasserstein–Weisfeiler–Lehman o variantes relacionadas. Esta selección permite comparar enfoques que privilegian distintas propiedades de los grafos: estadísticas estructurales resumidas, organización espectral global, patrones locales de vecindario y comportamiento multiescala.

El propósito de la tesis no es proponer una nueva métrica ni establecer una métrica universalmente superior. La contribución se orienta a evaluar empíricamente cómo distintas familias de comparación responden ante perturbaciones locales, mesoscópicas, globales, mixtas y distribucionales. Por ello, el análisis no se limita a observar si las distancias aumentan con la intensidad de perturbación, sino que considera sensibilidad, detectabilidad pareada, robustez, interpretabilidad y costo computacional.

Descripción de la situación problemática

El problema metodológico surge porque no existe una única función de comparación entre distribuciones de grafos que sea igualmente adecuada para todos los

tipos de cambio estructural. Una función puede ser sensible a modificaciones locales, como alteraciones de aristas, grados o vecindarios inmediatos, pero poco sensible a cambios globales, como debilitamiento de comunidades, variación de conectividad o modificación de propiedades espectrales. De forma inversa, una firma global puede detectar cambios en conectividad general, pero suavizar perturbaciones locales pequeñas.

Dada una secuencia de intensidades:

$$0 = \alpha_0 < \alpha_1 < \dots < \alpha_k \leq 1,$$

se obtiene una trayectoria de distribuciones perturbadas:

$$\mathcal{P}_{\alpha_0}, \mathcal{P}_{\alpha_1}, \dots, \mathcal{P}_{\alpha_k}, \quad \mathcal{P}_{\alpha_0} = \mathcal{P}.$$

Para una función de comparación D_j , se calcula la serie:

$$d_j(\alpha_i) = D_j(\mathcal{P}, \mathcal{P}_{\alpha_i}), \quad i = 0, \dots, k.$$

Una primera expectativa razonable es que, si la perturbación aumenta, la distancia tienda también a aumentar. Sin embargo, esta propiedad no debe confundirse con el aporte principal de la investigación. La monotonidad es útil como criterio de consistencia o control mínimo del experimento, pero por sí sola no basta para caracterizar el comportamiento de una métrica. En muchos protocolos controlados, que una curva promedio crezca con α puede ser esperable, especialmente si los resultados se agregan por media.

Por ello, esta tesis prioriza una pregunta más fina: qué tan rápido, con qué estabilidad y ante qué tipo de perturbación responde cada familia de comparación. Además, se considera el análisis pareado entre cada grafo original G_i y su versión perturbada G_i^α , ya que el diseño experimental conserva la relación directa entre ambos. Esta perspectiva permite evaluar no solo si dos muestras se separan en promedio, sino si cada grafo experimenta un cambio estructural progresivo bajo la representación utilizada.

La dificultad aumenta porque las familias evaluadas capturan información estructural distinta. Los métodos basados en MMD con descriptores estructurales dependen de las estadísticas seleccionadas, como grados, clustering, densidad o conteo de triángulos. Los métodos espectrales, como NetLSD, resumen propiedades de difusión, conectividad y estructura global mediante firmas laplacianas. Los métodos basados en Weisfeiler–Lehman refinan información de vecindarios y pueden responder con mayor sensibilidad a modificaciones locales o mesoscópicas. En consecuencia, no basta con comparar puntajes finales: es necesario estudiar perfiles de respuesta por tipo de perturbación, nivel de análisis y costo computacional.

Formulación del problema

Sea $\mathcal{P}$ una distribución de grafos sobre $\mathcal{G}$ y sea $\{\mathcal{T}_\alpha\}_{\alpha \in [0,1]}$ una familia de operadores de perturbación estructural. Para cada intensidad α , se define:

$$\mathcal{P}_\alpha = \mathcal{T}_\alpha(\mathcal{P}).$$

Dada una familia finita de funciones de comparación:

$$\mathcal{D} = \{D_{\text{MMD}}, D_{\text{Spec}}, D_{\text{WL}}, D_{\text{Multi}}\},$$

donde cada elemento representa una familia metodológica: descriptores estructurales agregados mediante Maximum Mean Discrepancy, firmas espectrales, representaciones basadas en Weisfeiler–Lehman y representaciones multiescala. La variante Wasserstein–Weisfeiler–Lehman se considera una extensión natural de D_{WL} y se discute en el marco teórico, pero su evaluación empírica queda fuera del alcance de esta etapa por su costo computacional. A partir de esta familia se busca analizar el comportamiento de:

$$d_D(\alpha) = D(\mathcal{P}, \mathcal{P}_\alpha), \quad D \in \mathcal{D}.$$

El problema general de investigación se formula de la siguiente manera:

¿Cómo responden distintas familias de funciones de comparación entre distribuciones de grafos ante perturbaciones estructurales controladas, y cómo varía su sensibilidad, detectabilidad pareada, robustez, interpretabilidad y costo computacional según el tipo de perturbación aplicada?

De este problema general se derivan las siguientes preguntas específicas:

1. ¿Qué perfiles de sensibilidad presentan las distintas familias de comparación ante perturbaciones locales, mesoscópicas, globales, mixtas y distribucionales?
2. ¿Qué métodos detectan cambios estructurales con mayor rapidez cuando aumenta la intensidad de perturbación α ?
3. ¿La relación entre intensidad de perturbación y puntaje de discrepancia se mantiene cuando se analiza a nivel pareado, es decir, comparando cada grafo original G_i con su versión perturbada G_i^α ?

4. ¿La monotonía observada en curvas agregadas se conserva al analizar distancias pareadas individuales, correlaciones por par y variabilidad entre semillas?
5. ¿Qué familias de comparación son más adecuadas para perturbaciones locales, como inserción o eliminación de aristas, modificación de vecindarios o alteración de triángulos?
6. ¿Qué familias de comparación son más adecuadas para perturbaciones mesoscópicas o globales, como debilitamiento de comunidades, modificación de hubs, rewiring preservando grado o cambios en conectividad?
7. ¿Qué costo computacional presenta cada familia en función del número de grafos, nodos, aristas y parámetros internos del método?

La hipótesis metodológica es que las familias de comparación no responderán de manera uniforme. Se espera que los métodos basados en Weisfeiler–Lehman sean especialmente sensibles a perturbaciones que alteran vecindarios y subestructuras locales, debido al refinamiento iterativo de etiquetas. Se espera que los métodos espectrales y multiescala respondan con mayor claridad ante perturbaciones que afectan conectividad global, difusión, estructura comunitaria o distancias de caminos. Los métodos MMD con descriptores estructurales se interpretan como líneas base: deberían responder bien cuando la perturbación afecta directamente las estadísticas seleccionadas, pero podrían subestimar cambios que ocurren fuera de dichas estadísticas. Estas hipótesis no implican superioridad universal de una familia, sino expectativas condicionadas al tipo de perturbación y al nivel de medición.

Objetivos de investigación

Objetivo general.

Evaluar empíricamente el comportamiento de distintas familias de funciones de comparación entre distribuciones de grafos sometidas a perturbaciones estructurales controladas, considerando sensibilidad, detectabilidad pareada, monotonicidad como criterio de consistencia, robustez, interpretabilidad y costo computacional.

Objetivos específicos.

1. Formalizar un protocolo experimental para generar distribuciones de grafos perturbadas $\mathcal{P}_\alpha$ a partir de una distribución base $\mathcal{P}$ mediante operadores $\mathcal{T}_\alpha$ con intensidades discretas de perturbación.
2. Implementar workflows representativos de comparación de distribuciones de grafos, incluyendo MMD con descriptores estructurales, firmas espectrales o multiescala, y métodos basados en Weisfeiler–Lehman o Wasserstein–Weisfeiler–Lehman.
3. Clasificar las perturbaciones estructurales según el nivel de organización que afectan: local, mesoscópico, global, mixto o distribucional.
4. Medir la sensibilidad de cada workflow frente a incrementos de α , considerando tanto curvas agregadas como cambios pareados entre grafos originales y perturbados.
5. Evaluar la relación entre α y los puntajes producidos por cada método mediante correlaciones ordinales, tales como Spearman- ρ y Kendall- τ , interpretándolas como indicadores de consistencia y no como evidencia suficiente de superioridad.
6. Incorporar análisis pareado mediante distancias $d(\phi(G_i), \phi(G_i^\alpha))$ para evaluar si el cambio estructural es capturado a nivel individual y no solo mediante promedios distribucionales.

7. Aplicar pruebas estadísticas apropiadas sobre diferencias pareadas cuando corresponda, con el fin de distinguir cambios observables de variaciones atribuidos a ruido experimental o semillas aleatorias.
8. Evaluar el costo computacional de cada familia registrando tiempo de ejecución, memoria aproximada y escalabilidad respecto de $|S|$, $|V|$, $|E|$ y parámetros internos del método.
9. Proponer criterios empíricos de selección de funciones de comparación según el tipo de perturbación, la escala estructural afectada y las restricciones computacionales.

Justificación

La investigación se justifica porque la comparación entre distribuciones de grafos sigue siendo metodológicamente delicada. Distintas métricas pueden producir conclusiones diferentes sobre el mismo conjunto de grafos, no necesariamente porque una sea incorrecta, sino porque cada una preserva y compara información estructural distinta. En evaluación de modelos generativos, por ejemplo, una métrica basada en grados puede sugerir similitud aunque el modelo no reproduzca comunidades, caminos, triángulos, hubs o diversidad estructural.

Desde el punto de vista teórico, la tesis contribuye a organizar el análisis de funciones de comparación según el tipo de estructura que capturan. MMD con descriptores estructurales representa una línea base interpretable, pero dependiente de la elección de estadísticas. Las firmas espectrales, como NetLSD, permiten estudiar propiedades globales y multiescala asociadas a conectividad y difusión. Los métodos basados en Weisfeiler–Lehman y Wasserstein permiten analizar patrones de vecindario y distribuciones de representaciones locales.

Desde el punto de vista metodológico, el uso de perturbaciones controladas permite construir trayectorias experimentales con causa conocida:

$$\mathcal{P} \rightarrow \mathcal{P}_{\alpha_1} \rightarrow \dots \rightarrow \mathcal{P}_{\alpha_k}.$$

Esta estrategia permite observar si una función de comparación responde de forma coherente cuando la estructura se aleja progresivamente de la distribución original. Sin embargo, la investigación no se limita a verificar que las curvas promedio aumenten. El análisis considera también la velocidad de respuesta, la estabilidad entre repeticiones, la evidencia pareada y los casos en los que una métrica detecta o no detecta cambios esperados.

Desde el punto de vista práctico, los resultados pueden orientar la selección de métricas para evaluación de modelos generativos de grafos, análisis de robustez, comparación de datasets y detección de cambio distribucional. La contribución esperada no es una regla universal, sino una caracterización empírica de fortalezas, limitaciones y costos bajo un protocolo reproducible.

Alcance y limitaciones

El alcance de esta investigación se limita a una comparación experimental entre familias representativas de funciones de comparación de distribuciones de grafos. No se pretende cubrir exhaustivamente todas las métricas existentes ni todas las variantes posibles de cada familia.

El estudio considera dos tipos de conjuntos de grafos: datasets sintéticos, que constituyen el núcleo del experimento, y datasets reales, utilizados como validación secundaria. La decisión de utilizar principalmente datasets sintéticos responde a la necesidad de evaluar las funciones de comparación entre distribuciones de grafos

bajo un entorno controlado. En este contexto, los modelos sintéticos permiten conocer de antemano la estructura generativa del grafo y controlar explícitamente las perturbaciones aplicadas, lo que facilita analizar de manera más precisa propiedades como sensibilidad, monotonidad, robustez, detectabilidad e interpretabilidad.

Además, muchas estructuras presentes en grafos reales pueden entenderse como combinaciones o manifestaciones de patrones estructurales básicos, tales como aleatoriedad, comunidades, hubs, regularidad geométrica, estructuras tipo árbol o propiedades de mundo pequeño. Por ello, los datasets sintéticos permiten aislar estos patrones y estudiar el comportamiento de las métricas antes de enfrentar la mayor complejidad, ruido y heterogeneidad de los datasets reales. En ese sentido, el análisis sintético funciona como una etapa metodológica previa y controlada, necesaria para interpretar con mayor claridad los resultados obtenidos posteriormente en grafos naturales.

Los datasets sintéticos considerados incluyen Erdős–Rényi, Stochastic Block Model o Community, Barabási–Albert, Watts–Strogatz, Grid y Lobster. Cada uno cumple una función metodológica específica: Erdős–Rényi permite controlar la densidad y el ruido aleatorio; SBM o Community permite evaluar la estructura mesoscópica y la presencia de comunidades; Barabási–Albert introduce hubs y distribuciones de grado tipo *heavy-tail*; Watts–Strogatz permite analizar propiedades de mundo pequeño y procesos de *rewiring*; mientras que Grid y Lobster representan estructuras regulares, geométricas o similares a árboles.

Como complemento, la validación con datos reales se centra en IMDB-BINARY, un conjunto de grafos de coaparición sin atributos complejos que resulta consistente con el espacio $\mathcal{G}$ de grafos simples y no etiquetados considerado en este trabajo. Este dataset no cumple el rol principal de controlar la perturbación, sino de verificar si los comportamientos observados en escenarios sintéticos se mantienen en grafos naturales con variabilidad estructural de tamaño y conectividad. Otros conjuntos de

referencia habituales como PROTEINS o ENZYMES para estructuras biológicas se contemplan como extensión natural de esta validación, pero su incorporación queda fuera del alcance de la etapa actual. Se evita deliberadamente el uso de datasets cuya información distintiva reside en atributos de nodos o aristas, como los grafos moleculares con atributos, dado que los workflows evaluados operan sobre estructura y no explotarían dicha información. De este modo, los datasets sintéticos permiten construir una evaluación controlada y granular, mientras que IMDB-BINARY permite un primer contraste de la capacidad de generalización de las conclusiones hacia dominios más cercanos a aplicaciones reales.

Las perturbaciones consideradas incluyen operaciones locales, como inserción o eliminación de aristas y triángulos; operaciones mesoscópicas, como debilitamiento de comunidades; operaciones globales, como modificación de hubs, rewiring preservando grado o alteración de conectividad; y operaciones distribucionales, como colapso de modos o pérdida de diversidad de la muestra.

En datasets que no proporcionen etiquetas explícitas de comunidad, cualquier partición obtenida mediante detección de comunidades se tratará como pseudo-etiqueta estructural o partición inferida. Estas particiones no serán interpretadas como ground truth semántico. Esta restricción es importante para evitar atribuir significado real a comunidades generadas por un algoritmo auxiliar.

Las conclusiones de la tesis serán empíricas y estarán condicionadas a los modelos, perturbaciones, parámetros, tamaños de muestra y workflows evaluados. Por ello, no se afirmará que una métrica es mejor en sentido universal. Las comparaciones se formularán en función del tipo de perturbación, el criterio de evaluación y el contexto experimental.

CAPÍTULO I

REVISIÓN CRÍTICA DE LA LITERATURA

1.1 De la evaluación de grafos generados a la comparación de distribuciones de grafos

La literatura sobre modelos generativos de grafos ha abordado tradicionalmente la evaluación desde una pregunta práctica: determinar si un conjunto de grafos generados se parece suficientemente a un conjunto de grafos reales o de referencia. Este enfoque aparece con claridad en trabajos como GraphRNN, donde la calidad de generación se evalúa comparando conjuntos de grafos mediante estadísticas estructurales, como distribución de grados, coeficiente de clustering y conteos de órbitas, agregadas mediante Maximum Mean Discrepancy (MMD) [1].

Sin embargo, la presente investigación se desplaza hacia una pregunta metodológicamente distinta. No se busca evaluar directamente si un modelo generativo produce grafos plausibles, sino estudiar si una función de comparación entre distribuciones de grafos es capaz de detectar, cuantificar y diferenciar cambios estructurales inducidos por perturbaciones controladas. En consecuencia, el objeto de análisis no es el modelo generativo, sino el comportamiento de la función de comparación.

Sea $\mathcal{G}$ el espacio de grafos simples, no dirigidos y finitos. Una distribución de grafos se representa como una medida de probabilidad $\mathcal{P}$ sobre $\mathcal{G}$. Dado un operador de perturbación $\mathcal{T}_\alpha$, con intensidad $\alpha \in [0, 1]$, se define la distribución perturbada como:

$$\mathcal{P}_\alpha = \mathcal{T}_\alpha(\mathcal{P}).$$

El problema central consiste en estudiar el comportamiento de una función de comparación:

$$D(\mathcal{P}, \mathcal{P}_\alpha)$$

cuando α aumenta progresivamente. Esta formulación transforma la evaluación de calidad generativa en un problema de sensibilidad, detectabilidad, consistencia y discriminación entre distribuciones.

Este cambio de enfoque es importante porque una métrica útil para evaluar grafos generados no necesariamente es adecuada para caracterizar perturbaciones estructurales finas. Una medida puede detectar diferencias gruesas entre grafos reales y sintéticos, pero ser insuficiente para establecer qué tipo de cambio fue capturado, desde qué intensidad se vuelve detectable o si la respuesta se mantiene al analizar pares grafo original–grafo perturbado.

1.2 Distribuciones de grafos, representaciones y riesgo de agregación

Una parte significativa de la literatura estudia grafos individuales o colecciones de grafos como datos empíricos. No obstante, para analizar sensibilidad de métricas se requiere trabajar con distribuciones generativas o muestras controladas. En este contexto, una familia de distribuciones de grafos puede escribirse como:

$$\{\mathcal{P}_\theta : \theta \in \Theta\},$$

donde θ representa parámetros propios del modelo generativo base. Por ejemplo, en Erdős–Rényi, θ puede incluir el número de nodos y la probabilidad de arista; en Stochastic Block Model, puede incluir el número de bloques y las probabilidades

intra/intercomunidad; en Barabási–Albert, puede incluir el mecanismo de crecimiento y conexión preferencial.

En esta investigación debe distinguirse entre el parámetro generativo θ y la intensidad de perturbación α . El primero define la familia base de grafos; el segundo controla el grado de alteración aplicado sobre una muestra o distribución. Para cada intensidad α_i se obtiene una muestra perturbada:

$$S_{\alpha_i} = \{G_1^{(\alpha_i)}, \dots, G_n^{(\alpha_i)}\}, \quad G_j^{(\alpha_i)} \sim \mathcal{P}_{\alpha_i}.$$

La comparación empírica se expresa como:

$$\hat{D}(S_0, S_{\alpha_i}) \approx D(\mathcal{P}, \mathcal{P}_{\alpha_i}).$$

Sin embargo, existe un riesgo metodológico: si el análisis se limita a promediar puntajes por cada valor de α , las curvas pueden mostrar una tendencia aparentemente monotónica aun cuando los cambios individuales sean heterogéneos. Por ello, la evaluación no debe depender únicamente de promedios distribucionales. Cuando el protocolo conserva correspondencia entre cada grafo original y su versión perturbada, debe aprovecharse el análisis pareado:

$$p_{i,\alpha} = d(\phi(G_i), \phi(G_i^\alpha)).$$

Este nivel permite estudiar si la representación ϕ detecta de manera progresiva el cambio aplicado a cada grafo, y no solo si las medias de dos muestras se separan.

1.3 MMD con descriptores estructurales como línea base

Maximum Mean Discrepancy se ha consolidado como una herramienta estándar para comparar distribuciones empíricas de grafos en evaluación de modelos generativos. Su uso típico consiste en extraer de cada grafo un descriptor estructural, como distribución de grados, clustering o conteo de motivos, y luego comparar las distribuciones empíricas de dichos descriptores mediante un kernel [1–3].

Dadas dos muestras de grafos:

$$S = \{G_1, \dots, G_m\}, \quad S' = \{G'_1, \dots, G'_n\},$$

y una función descriptora:

$$\phi : \mathcal{G} \rightarrow \mathbb{R}^d,$$

MMD compara las muestras transformadas:

$$X = \{\phi(G_i)\}_{i=1}^m, \quad Y = \{\phi(G'_j)\}_{j=1}^n.$$

El estimador empírico puede escribirse como:

$$\widehat{\text{MMD}}^2(X, Y) = \frac{1}{m^2} \sum_{i=1}^m \sum_{i'=1}^m k(x_i, x_{i'}) + \frac{1}{n^2} \sum_{j=1}^n \sum_{j'=1}^n k(y_j, y_{j'}) - \frac{2}{mn} \sum_{i=1}^m \sum_{j=1}^n k(x_i, y_j),$$

donde k es un kernel positivo definido, típicamente RBF.

La fortaleza de este enfoque es su simplicidad, interpretabilidad y adopción amplia como línea base. Si una perturbación altera directamente grados, densidad, clustering o conteos de triángulos, un descriptor diseñado para capturar esa propiedad debería responder de forma clara. No obstante, su limitación principal es que la distancia depende críticamente del descriptor elegido. Si ϕ captura grados, pero no estructura comunitaria, la métrica puede subestimar perturbaciones mesoscópicas. Si captura clustering, pero no caminos largos ni conectividad espectral, puede fallar ante perturbaciones globales.

Por tanto, MMD con descriptores no debe entenderse como una distancia universal entre grafos, sino como una familia de pruebas dirigidas a propiedades específicas. En esta tesis, su función será establecer una línea base interpretable frente a métodos que incorporan mayor contenido estructural, como firmas espectrales, métodos multiescala y enfoques basados en Weisfeiler–Lehman.

1.4 Métodos espectrales y comparación multiescala

Las distancias espectrales comparan grafos mediante autovalores asociados a matrices como la matriz de adyacencia, el Laplaciano combinatorio o el Laplaciano normalizado. Su fundamento es que el espectro codifica información sobre conectividad, componentes, cortes, comunidades y procesos de difusión [4, 5].

Sea $G = (V, E)$ un grafo y sea L su Laplaciano. Si:

$$0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$$

son los autovalores de L , una distancia espectral básica entre dos grafos G y H puede expresarse como:

$$d_{\text{spec}}(G, H) = \left(\sum_{i=1}^k (\lambda_i(G) - \lambda_i(H))^2 \right)^{1/2}.$$

Esta distancia espectral básica tiene una limitación práctica: presupone espectros de igual longitud y alineados posición a posición, lo que no se cumple cuando los grafos comparados difieren en número de nodos. NetLSD constituye una alternativa espectral relevante precisamente porque evita esa dificultad: en lugar de comparar autovalores individuales, construye una firma continua en el tiempo de difusión t a partir de la traza del kernel de calor asociado al Laplaciano, definida de manera consistente para grafos de distinto tamaño y susceptible de normalización [6]. Su forma general puede escribirse como:

$$h_G(t) = \text{Tr} (e^{-tL}) = \sum_{i=1}^n e^{-t\lambda_i},$$

donde t controla la escala de observación. Valores pequeños de t tienden a capturar información más local, mientras que valores grandes reflejan propiedades globales de difusión.

Esta característica hace que NetLSD sea especialmente pertinente para evaluar perturbaciones estructurales. Una firma multiescala permite estudiar no solo si dos distribuciones son diferentes, sino también si la diferencia aparece en escalas locales, intermedias o globales. No obstante, las métricas espectrales también tienen limitaciones. Pueden suavizar perturbaciones locales pequeñas si estas no alteran de manera significativa el espectro, y existen grafos no isomorfos con espectros iguales o muy similares. Por ello, deben compararse con métodos más sensibles a vecindarios y subestructuras.

1.5 Weisfeiler–Lehman y Wasserstein–Weisfeiler–Lehman

Los métodos basados en Weisfeiler–Lehman se apoyan en un procedimiento iterativo de refinamiento de etiquetas. En cada iteración, la representación de un nodo se actualiza combinando su etiqueta actual con las etiquetas de sus vecinos. De forma esquemática:

$$c_{h+1}(v) = \text{hash}(c_h(v), \{\{c_h(u) : u \in N(v)\}\}),$$

donde $c_h(v)$ es la etiqueta del nodo v en la iteración h , $N(v)$ es su vecindario y $\{\{\cdot\}\}$ representa un multiconjunto.

Después de h iteraciones, la representación del grafo incorpora información de vecindarios de radio creciente [7]. Esta propiedad ofrece una hipótesis natural para la presente investigación: los métodos basados en Weisfeiler–Lehman deberían ser especialmente sensibles a perturbaciones locales y mesoscópicas, como recableado parcial, alteración de triángulos, modificación de vecindarios o cambios en subestructuras repetidas.

Wasserstein–Weisfeiler–Lehman extiende esta idea al comparar distribuciones de embeddings de nodos mediante distancia Wasserstein [8]. Dadas dos matrices de embeddings de nodos:

$$X_G \in \mathbb{R}^{n_G \times d}, \quad X_H \in \mathbb{R}^{n_H \times d},$$

la distancia Wasserstein entre ambos conjuntos puede expresarse como:

$$W_1(X_G, X_H) = \min_{P \in \Gamma(X_G, X_H)} \langle P, M \rangle,$$

donde M contiene los costos de transporte entre embeddings y P es un plan de transporte admisible.

Para esta tesis, WWL es relevante porque ocupa una posición intermedia entre comparación local y comparación distribucional. Captura patrones de vecindario mediante WL, pero compara distribuciones internas de representaciones mediante transporte óptimo. Su principal limitación es el costo computacional, por lo que su evaluación debe incluir tiempo de ejecución y escalabilidad.

1.6 Modelos sintéticos y estructura controlable

La elección de distribuciones base es decisiva. Si solo se evalúa una familia de grafos, los resultados pueden confundirse con propiedades particulares de esa familia. Por ello, la literatura sobre redes complejas utiliza modelos sintéticos para aislar mecanismos estructurales específicos.

El modelo Erdős–Rényi permite estudiar grafos con aleatoriedad homogénea y probabilidad uniforme de arista [9]. Su utilidad en esta tesis consiste en funcionar como caso base donde no existen comunidades ni hubs marcados por construcción.

El Stochastic Block Model permite generar grafos con estructura de bloques o comunidades, controlando probabilidades de conexión intra e intercomunidad [10]. Este modelo es especialmente importante porque las etiquetas comunitarias forman parte del proceso generativo, por lo que pueden tratarse como ground truth estructural dentro del experimento sintético.

El modelo Barabási–Albert introduce crecimiento y conexión preferencial, generando distribuciones de grado heterogéneas y presencia de hubs [11]. Este modelo permite evaluar perturbaciones sobre nodos de alta conectividad y observar si las métricas capturan cambios con efectos globales.

El modelo Watts–Strogatz permite estudiar grafos con propiedades de mundo pequeño, combinando alto clustering y caminos relativamente cortos [12]. Es útil para evaluar perturbaciones que alteran clustering, recableado y estructura de caminos.

Los grafos Grid permiten representar regularidad geométrica y localidad estructural. Aunque no corresponden necesariamente a un modelo probabilístico complejo, sirven como familia controlada para estudiar perturbaciones sobre conectividad regular y caminos.

Los grafos tipo *lobster* permiten estudiar estructuras arbóreas ramificadas. Un grafo *lobster* puede entenderse como un árbol que se transforma en un camino al remover hojas y luego remover nuevamente las hojas restantes. Esta familia es útil para perturbaciones sobre ramas, hojas, caminos y vecindarios locales sin introducir ciclos densos.

Estos modelos no buscan reproducir toda la complejidad de las redes reales. Su función metodológica es aislar mecanismos estructurales para observar qué familias de comparación responden ante qué tipo de cambio.

1.7 Comunidades reales, comunidades generativas y pseudo-etiquetas

Las perturbaciones dependientes de comunidad requieren una distinción conceptual cuidadosa. No todas las comunidades utilizadas en un experimento tienen el mismo estatus.

En modelos como Stochastic Block Model, las comunidades forman parte del proceso generativo. Por tanto, las etiquetas de comunidad pueden interpretarse como estructura conocida del experimento. En cambio, en datasets reales o en familias sintéticas que no proporcionan etiquetas comunitarias, cualquier partición obtenida

mediante un algoritmo de detección debe tratarse como una comunidad inferida, no como ground truth.

En aquellos conjuntos de grafos que no proporcionan etiquetas explícitas de comunidades a nivel de nodos, puede utilizarse un procedimiento auxiliar de detección de comunidades basado en maximización greedy de la modularidad, siguiendo el algoritmo de Clauset, Newman y Moore [13]. Esta decisión no debe interpretarse como generación de comunidades reales ni como recuperación garantizada de una estructura semántica. Su función es operacional: obtener particiones estructurales aproximadas sobre las cuales aplicar perturbaciones controladas dependientes de comunidad.

En consecuencia, las comunidades obtenidas de esta manera se tratan como pseudo-etiquetas o particiones inferidas. Para que su uso sea metodológicamente defendible, deben reportarse el algoritmo utilizado, sus parámetros, si el procedimiento es determinístico, el tratamiento de semillas aleatorias y cualquier medida de estabilidad o calidad de partición que se utilice. Si las particiones inferidas no muestran una relación estructural clara con el grafo, las perturbaciones dependientes de comunidad deben interpretarse como análisis exploratorio y no como evidencia concluyente sobre comunidades reales.

1.8 Perturbaciones estructurales e intensidad de cambio

Las perturbaciones controladas permiten transformar el problema de comparación de grafos en un experimento con causa conocida. En lugar de comparar dos colecciones arbitrarias de grafos, se construye una trayectoria de muestras perturbadas:

$$S_0, S_{\alpha_1}, \dots, S_{\alpha_k}.$$

Las perturbaciones pueden clasificarse según la escala estructural afectada.

Las perturbaciones locales modifican aristas, grados, triángulos, hojas, ramas o vecindarios inmediatos. Estas perturbaciones son relevantes para evaluar métodos sensibles a patrones pequeños o subestructuras repetidas.

Las perturbaciones mesoscópicas alteran comunidades, bloques o patrones de cohesión intermedia. El debilitamiento de comunidades pertenece a esta categoría, ya que puede preservar estadísticas globales simples mientras degrada la organización de grupos.

Las perturbaciones globales modifican conectividad, caminos, hubs, componentes o propiedades espectrales. La modificación de hubs o el rewiring preservando grado pueden producir cambios globales aun cuando algunas estadísticas locales permanezcan estables.

Las perturbaciones distribucionales modifican la composición de la muestra, no necesariamente cada grafo individual. El colapso distribucional o *mode dropping* ocurre cuando una muestra conserva grafos plausibles, pero pierde diversidad estructural o deja de cubrir ciertos modos de la distribución original. Esta perturbación es relevante para evaluación de modelos generativos porque un modelo puede producir grafos individualmente razonables y, aun así, representar solo una parte de la distribución objetivo.

1.9 Criterios críticos de comparación entre métricas

La revisión de la literatura permite identificar varios criterios necesarios para comparar funciones de discrepancia entre distribuciones de grafos.

Sensibilidad. Mide si una función de comparación reacciona ante cambios estructurales relevantes. En esta tesis, la sensibilidad no se entiende únicamente como

aumento del puntaje, sino como capacidad de detectar cambios desde intensidades bajas, diferenciar tipos de perturbación y producir respuestas consistentes con la escala estructural afectada.

Detectabilidad pareada. Evalúa si el cambio entre cada grafo original y su versión perturbada aumenta conforme crece α . Se define a nivel individual como:

$$p_{i,\alpha} = d(\phi(G_i), \phi(G_i^\alpha)).$$

Este criterio evita depender únicamente de promedios distribucionales y permite analizar la variabilidad de respuesta entre grafos.

Monotonidad. Evalúa si el puntaje tiende a aumentar cuando aumenta la intensidad de perturbación. Sin embargo, debe interpretarse como criterio de consistencia o sanity check, no como aporte central. Una respuesta monotónica en curvas agregadas puede ser esperable bajo perturbaciones controladas, especialmente si se trabaja con medias.

Robustez. Mide la estabilidad de los resultados ante semillas, repeticiones experimentales y variaciones de configuración. Una métrica sensible pero inestable puede ser menos útil que una métrica moderadamente sensible pero reproducible.

Interpretabilidad. Evalúa si el puntaje puede relacionarse con propiedades estructurales comprensibles, como grados, clustering, comunidades, hubs, caminos o difusión espectral.

Costo computacional. Considera tiempo de ejecución, memoria y escalabilidad respecto del número de grafos, nodos, aristas y parámetros internos. Este criterio es indispensable porque algunas métricas pueden ser expresivas pero poco viables para muestras grandes.

1.10 Síntesis crítica y brecha de investigación

La literatura existente ofrece herramientas importantes para comparar grafos y distribuciones de grafos. MMD con descriptores estructurales es ampliamente utilizado y fácilmente interpretable, pero depende de las estadísticas seleccionadas. NetLSD y otras firmas espectrales ofrecen descripciones globales y multiescala, pero pueden suavizar perturbaciones locales pequeñas. Los métodos basados en Weisfeiler–Lehman y Wasserstein capturan vecindarios y distribuciones internas de representaciones, pero pueden presentar mayor costo computacional.

La brecha que aborda esta tesis no consiste en proponer una nueva métrica ni en repetir comparaciones generales entre métodos. La contribución consiste en evaluar comparativamente cómo distintas familias de comparación responden ante perturbaciones estructurales controladas, considerando no solo curvas promedio, sino también análisis pareado, sensibilidad por tipo de perturbación, evidencia estadística, robustez, interpretabilidad y costo computacional.

En consecuencia, la tesis no pregunta qué métrica es mejor en sentido universal. Pregunta qué familia de comparación resulta más informativa bajo determinados tipos de perturbación y bajo determinados criterios de evaluación.

CAPÍTULO II

MARCO TEÓRICO

La comparación de grafos constituye un problema central en diversas áreas de las Ciencias de la Computación, especialmente en aprendizaje automático, minería de datos, análisis de redes complejas y evaluación de modelos generativos. Aunque la teoría básica de grafos proporciona el lenguaje formal para representar relaciones entre objetos, muchos problemas actuales no se limitan a estudiar grafos individuales. Con frecuencia, el interés se orienta a comparar colecciones de grafos, identificar cambios estructurales entre poblaciones y evaluar si dos conjuntos de redes comparten propiedades topológicas similares [1, 3, 14].

Este capítulo desarrolla los conceptos teóricos necesarios para comprender la comparación de distribuciones de grafos desde una perspectiva computacional. No se busca presentar una revisión exhaustiva de todas las métricas de grafos, sino introducir los fundamentos que justifican la metodología de la tesis: comparación entre muestras de grafos, representaciones estructurales, escalas topológicas, familias de métricas, modelos sintéticos, perturbaciones controladas, comunidades inferidas y criterios de evaluación.

2.1 Comparación de grafos como problema computacional

Comparar grafos es más complejo que comparar vectores o matrices convencionales. En primer lugar, la representación matricial de un grafo no es única. Un mismo grafo puede representarse mediante distintas matrices de adyacencia dependiendo del orden asignado a sus nodos. Por tanto, una función de comparación

adecuada debe ser invariante a permutaciones de nodos, salvo que exista una correspondencia semántica explícita entre vértices.

En segundo lugar, los grafos pueden variar en tamaño. Dos grafos comparados pueden tener distinto número de nodos y aristas, lo que dificulta el uso directo de distancias matriciales. Esta variabilidad exige representaciones capaces de comparar estructuras sin depender exclusivamente de dimensiones idénticas.

En tercer lugar, las dependencias estructurales de un grafo no son puramente locales. La modificación de una arista puede afectar caminos, ciclos, comunidades, componentes, centralidad y propiedades espectrales. De manera inversa, dos grafos pueden compartir estadísticas locales y diferir globalmente. Esta tensión entre estructura local y global explica por qué existen múltiples familias de métodos para comparar grafos [6, 15].

Finalmente, la comparación práctica debe considerar restricciones computacionales. Métodos expresivos como la distancia de edición de grafos pueden ser conceptualmente atractivos, pero resultan costosos para colecciones grandes. Por esta razón, la comparación de grafos suele recurrir a representaciones estructurales, kernels, firmas espectrales, descriptores estadísticos o embeddings.

2.2 Comparación de distribuciones de grafos

En numerosos escenarios, el objetivo no consiste en comparar únicamente dos grafos, sino dos conjuntos de grafos. Este problema aparece en la evaluación de modelos generativos, detección de cambio distribucional, análisis de redes dinámicas y comparación de datasets [1, 3].

Sea $\mathcal{S} = \{G_1, G_2, \dots, G_n\}$ una muestra de grafos de referencia, y sea $\mathcal{T} = \{H_1, H_2, \dots, H_m\}$ una segunda muestra. El problema consiste en estimar una medida de discrepancia entre ambas muestras:

$$\Delta(\mathcal{S}, \mathcal{T}) \geq 0.$$

En la práctica, esta discrepancia rara vez se calcula directamente sobre los grafos originales. Usualmente, cada grafo se transforma primero en una representación estructural:

$$\phi : \mathcal{G} \rightarrow \mathcal{X},$$

donde $\mathcal{X}$ puede ser un espacio vectorial, una firma espectral, un histograma, una distribución de embeddings o una curva multiescala. Así, la comparación entre muestras de grafos puede entenderse como una comparación entre distribuciones inducidas por la representación:

$$\Delta(\mathcal{S}, \mathcal{T}) = D \left(\{\phi(G_i)\}_{i=1}^n, \{\phi(H_j)\}_{j=1}^m \right).$$

Esta formulación permite separar dos decisiones: la representación ϕ , que determina qué información estructural se conserva, y la función D , que determina cómo se comparan las muestras representadas. Una comparación puede fallar porque la distancia no es adecuada, pero también porque la representación no captura la propiedad estructural afectada.

2.3 Escalas estructurales en grafos

La estructura de un grafo puede analizarse en distintas escalas. Esta distinción es importante porque las funciones de comparación no son igualmente sensibles a todos los niveles estructurales.

La escala local incluye propiedades asociadas a nodos, aristas y vecindarios pequeños. Entre ellas se encuentran grado, clustering, triángulos, motivos simples y vecindarios de primer o segundo orden [16].

La escala mesoscópica se ubica entre lo local y lo global. Incluye comunidades, bloques, motivos extendidos y patrones de vecindario repetidos. Los métodos basados en kernels de grafos y Weisfeiler–Lehman suelen ser relevantes en este nivel, porque agregan información de vecindarios de manera iterativa [7, 8].

La escala global comprende propiedades del grafo completo, como conectividad, componentes, diámetro, estructura de caminos, hubs, cortes y espectro del Laplaciano. Los métodos espectrales son especialmente relevantes porque los autovalores de matrices asociadas al grafo contienen información sobre conectividad y difusión [4, 5].

La perspectiva multiescala analiza la estructura del grafo en varios niveles de resolución. En lugar de reducir el grafo a una sola estadística, observa cómo cambian ciertas propiedades cuando se modifica una escala, un tiempo de difusión o un nivel de coarsening [6, 17].

2.4 Métodos basados en estadísticas estructurales y MMD

Una estrategia común para comparar distribuciones de grafos consiste en extraer estadísticas estructurales de cada grafo y comparar las distribuciones empíricas

de dichas estadísticas. Entre las estadísticas frecuentes se encuentran grado promedio, distribución de grados, densidad, clustering, transitividad, triángulos y componentes conexas [1, 3].

Este enfoque tiene una ventaja importante: sus resultados suelen ser interpretables. Si dos conjuntos difieren en distribución de grados, puede inferirse una diferencia en conectividad. Si difieren en clustering, puede interpretarse como una diferencia en cierre triádico o cohesión local. Sin embargo, esta claridad tiene una limitación: el método solo puede detectar cambios reflejados en las estadísticas seleccionadas.

Maximum Mean Discrepancy permite comparar distribuciones empíricas de descriptores estructurales [2]. Dadas dos muestras:

$$X = \{x_1, x_2, \dots, x_m\}, \quad Y = \{y_1, y_2, \dots, y_n\},$$

y un kernel positivo definido $k(\cdot, \cdot)$, el estimador empírico de MMD puede escribirse como:

$$\widehat{\text{MMD}}^2(X, Y) = \frac{1}{m^2} \sum_{i=1}^m \sum_{j=1}^m k(x_i, x_j) + \frac{1}{n^2} \sum_{i=1}^n \sum_{j=1}^n k(y_i, y_j) - \frac{2}{mn} \sum_{i=1}^m \sum_{j=1}^n k(x_i, y_j).$$

La expresión anterior corresponde al estimador sesgado de tipo V , que incluye los términos diagonales de los dobles sumatorios; existe también un estimador insesgado que los excluye y reemplaza los factores $1/m^2$ y $1/n^2$ por $1/(m(m-1))$ y $1/(n(n-1))$ [2]. La elección entre ambos, así como el ancho de banda del kernel, forman parte de la configuración del workflow y deben documentarse por su efecto sobre el puntaje.

En esta tesis, MMD se interpreta como una línea base fuerte pero dependiente de la representación. Su comportamiento debe evaluarse según si la perturbación afecta o no las estadísticas utilizadas.

2.5 Kernels de grafos y Weisfeiler–Lehman

Los kernels de grafos miden similitud entre grafos mediante subestructuras, como caminos, walks, subárboles o vecindarios [15, 18, 19]. En lugar de comparar matrices directamente, estos métodos descomponen los grafos en patrones internos y agregan similitudes entre ellos.

El Weisfeiler–Lehman subtree kernel es uno de los enfoques más influyentes. Se basa en un refinamiento iterativo de etiquetas de nodos [7]. Si $c_h(v)$ representa la etiqueta del nodo v en la iteración h , entonces el refinamiento puede expresarse de forma esquemática como:

$$c_{h+1}(v) = \text{hash}(c_h(v), \{\{c_h(u) : u \in N(v)\}\}).$$

Después de h iteraciones, cada nodo incorpora información de vecindarios de radio creciente. Por ello, los métodos basados en WL son adecuados para estudiar perturbaciones que alteran patrones locales o mesoscópicos. No obstante, dependen del número de iteraciones, de la codificación de etiquetas y de la forma en que se agregan las representaciones del grafo.

2.6 Transporte óptimo y Wasserstein–Weisfeiler–Lehman

El transporte óptimo proporciona un marco para comparar distribuciones considerando el costo mínimo de transformar una distribución en otra [20, 21]. En el

contexto de grafos, puede utilizarse para comparar distribuciones de representaciones internas, por ejemplo, embeddings de nodos.

Sean μ y ν dos distribuciones de probabilidad sobre un espacio métrico $(\mathcal{X}, d)$. La distancia de Wasserstein de orden p se define como:

$$W_p(\mu, \nu) = \left(\inf_{\gamma \in \Pi(\mu, \nu)} \int_{\mathcal{X} \times \mathcal{X}} d(x, y)^p d\gamma(x, y) \right)^{1/p},$$

donde $\Pi(\mu, \nu)$ es el conjunto de planes de transporte con marginales μ y ν .

Wasserstein–Weisfeiler–Lehman combina representaciones inspiradas en WL con distancia de Wasserstein para comparar grafos mediante distribuciones de representaciones de nodos [8]. Esta idea es importante porque evita reducir necesariamente cada grafo a un único vector promedio. Su limitación principal es el costo computacional, especialmente cuando se comparan muchas muestras o grafos grandes.

2.7 Representaciones espectrales y NetLSD

Las representaciones espectrales describen un grafo mediante autovalores o funciones de matrices asociadas, como el Laplaciano combinatorio o el Laplaciano normalizado [4, 5]. Estas representaciones son relevantes porque el espectro contiene información sobre conectividad, componentes, cortes, comunidades y difusión.

Sea L una matriz Laplaciana asociada a un grafo G , y sean sus autovalores:

$$0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n.$$

NetLSD propone una firma basada en la traza del heat kernel [6]:

$$h_G(t) = \text{tr} \left(e^{-tL} \right) = \sum_{i=1}^n e^{-t\lambda_i}.$$

El parámetro t funciona como escala de observación. Valores pequeños tienden a reflejar información local, mientras que valores grandes capturan propiedades globales de difusión. Por ello, NetLSD resulta relevante para estudiar perturbaciones que afectan conectividad global, estructura comunitaria o propiedades multiescala. Sin embargo, como firma agregada, puede no responder con fuerza ante perturbaciones locales pequeñas si estas no modifican significativamente el espectro.

2.8 Representaciones multiescala y coarsening

Los métodos multiescala analizan cómo cambia una propiedad estructural cuando el grafo se observa a distintos niveles de resolución. En enfoques basados en coarsening, el grafo se simplifica progresivamente mediante operaciones como contracción de aristas, y luego se estudia la evolución de una medida estructural.

Las Diversity Curves utilizan esta idea para construir representaciones de grafos basadas en diversidad estructural a través de niveles de coarsening [17]. De manera general, cada grafo se transforma en una curva que resume cómo se conserva o pierde diversidad estructural conforme se reduce su resolución.

Esta familia es relevante porque algunas diferencias no aparecen en una única escala. Dos grafos pueden parecer similares localmente, pero diferir globalmente; o compartir propiedades globales y diferir en organización intermedia. Por ello, los métodos multiescala complementan tanto a los descriptores simples como a las firmas espectrales.

2.9 Modelos sintéticos de grafos

Los modelos sintéticos permiten evaluar funciones de comparación bajo condiciones controladas. Su propósito no es reproducir toda la complejidad de los grafos reales, sino aislar propiedades estructurales específicas.

2.9.1 Erdős–Rényi

El modelo Erdős–Rényi genera grafos aleatorios a partir de una probabilidad uniforme de conexión entre pares de nodos [9]. En su variante $G(n, p)$, cada arista aparece independientemente con probabilidad p . Este modelo sirve como línea base de aleatoriedad homogénea, sin comunidades ni hubs explícitos.

2.9.2 Stochastic Block Model

El Stochastic Block Model genera grafos con estructura de bloques o comunidades [10]. Los nodos pertenecen a grupos latentes, y la probabilidad de arista depende de los bloques de origen y destino. Este modelo es importante porque las etiquetas comunitarias pertenecen al proceso generativo, por lo que las perturbaciones dependientes de comunidad están estructuralmente justificadas.

2.9.3 Barabási–Albert

El modelo Barabási–Albert introduce crecimiento y conexión preferencial, generando grafos con distribución de grado heterogénea y presencia de hubs [11]. Es útil para evaluar perturbaciones sobre nodos altamente conectados y analizar si las métricas capturan cambios con impacto global.

2.9.4 Watts–Strogatz

El modelo Watts–Strogatz genera grafos con propiedades de mundo pequeño, combinando alto clustering con caminos relativamente cortos [12]. Permite estudiar perturbaciones que alteran cierre local, rewiring y estructura de caminos.

2.9.5 Grid

Los grafos Grid representan estructuras regulares con organización geométrica. Aunque son menos flexibles como modelo generativo, permiten evaluar perturbaciones sobre conectividad local, caminos y regularidad estructural.

2.9.6 Lobster

Los grafos tipo *lobster* son árboles que se reducen a un camino luego de remover hojas y repetir la operación una vez más. Son útiles para estudiar perturbaciones en ramas, hojas y caminos sin introducir ciclos densos.

2.10 Comunidades, modularidad y pseudo-etiquetas

La noción de comunidad se refiere, de manera general, a grupos de nodos con mayor densidad de conexiones internas que externas. En modelos generativos como SBM, las comunidades están definidas por construcción. En cambio, en datasets reales o en modelos que no incluyen etiquetas comunitarias, las comunidades deben ser inferidas mediante algoritmos de detección.

Una estrategia común es maximizar la modularidad, que mide la calidad de una partición comparando la densidad de aristas internas observada con la esperada bajo un modelo nulo. El algoritmo de Clauset, Newman y Moore propone una aproximación greedy aglomerativa para detectar comunidades en redes grandes [13].

2.11 Perturbaciones controladas

Las perturbaciones controladas modifican grafos o muestras de grafos con una intensidad conocida α . Su objetivo es generar escenarios donde la causa del cambio estructural sea explícita.

Las perturbaciones locales afectan aristas, grados, triángulos, hojas o vecindarios pequeños. Sirven para evaluar sensibilidad a cambios de corto alcance.

Las perturbaciones mesoscópicas afectan comunidades, bloques o cohesión de grupos. El debilitamiento de comunidades pertenece a esta categoría.

Las perturbaciones globales afectan conectividad general, hubs, caminos, componentes o propiedades espectrales. Pueden tener efectos amplios incluso si la intervención se concentra en pocos nodos.

Las perturbaciones mixtas combinan efectos locales y globales, como el rewiring preservando grado. En este caso, la secuencia de grados puede mantenerse relativamente estable mientras cambian caminos, clustering o comunidades.

Las perturbaciones distribucionales modifican la composición de la muestra. El colapso distribucional ocurre cuando una distribución perturbada pierde modos estructurales presentes en la distribución original. Este caso es relevante para evaluar si una función de comparación detecta pérdida de diversidad, incluso cuando los grafos individuales parecen plausibles.

2.12 Análisis pareado e inferencia estadística

Cuando el protocolo experimental genera una versión perturbada G_i^α para cada grafo original G_i , se obtiene una estructura pareada. Esta estructura permite definir una distancia individual:

$$p_{i,\alpha} = d(\phi(G_i), \phi(G_i^\alpha)).$$

El análisis pareado es importante porque evita depender únicamente de promedios entre distribuciones. Dos muestras pueden separarse en promedio, pero no necesariamente mostrar cambios consistentes en cada trayectoria individual. Por ello, la relación entre α y $p_{i,\alpha}$ puede analizarse mediante correlaciones ordinales por par o mediante distribuciones de puntajes pareados.

Para comparar niveles de perturbación, pueden utilizarse pruebas estadísticas sobre diferencias pareadas. Si las diferencias entre dos niveles de perturbación presentan normalidad aproximada, puede aplicarse una prueba t pareada [22]. Si no se desea asumir normalidad, puede emplearse la prueba de rangos con signo de Wilcoxon como alternativa no paramétrica [23]. Cuando se realizan múltiples comparaciones entre métricas, perturbaciones o niveles de α , debe considerarse una corrección por comparaciones múltiples, como el procedimiento de Benjamini–Hochberg para controlar la tasa de falsos descubrimientos [24].

Estas pruebas no sustituyen el análisis estructural. Su función es apoyar la interpretación empírica y reducir el riesgo de concluir diferencias a partir de fluctuaciones aleatorias.

2.13 Criterios de evaluación de métodos

La evaluación de funciones de comparación entre distribuciones de grafos requiere varios criterios complementarios.

- **Sensibilidad.** Evalúa si el método responde ante cambios estructurales relevantes y desde qué intensidad de perturbación se vuelve observable la respuesta.
- **Detectabilidad pareada.** Evalúa si el cambio entre cada grafo original y su versión perturbada aumenta de forma consistente con α .
- **Monotonidad.** Evalúa si el puntaje evita disminuciones conforme aumenta la perturbación. En esta tesis, se interpreta como criterio de consistencia, no como aporte principal.
- **Robustez.** Evalúa estabilidad ante semillas, repeticiones y variaciones de configuración.
- **Interpretabilidad.** Evalúa si el puntaje puede relacionarse con propiedades estructurales comprensibles.
- **Costo computacional.** Evalúa tiempo de ejecución, memoria y escalabilidad.
- **Granularidad estructural.** Evalúa qué tipo de perturbaciones detecta mejor cada familia: locales, mesoscópicas, globales, mixtas o distribucionales.

En conjunto, estos criterios permiten evitar una comparación superficial basada únicamente en magnitudes absolutas. La tesis se orienta a caracterizar perfiles de comportamiento, no a declarar una métrica universalmente superior.

CAPÍTULO III

MARCO REFERENCIAL (LEGAL, GEOGRÁFICO, HISTÓRICO) (opcional)

Inicie aquí el texto, utilizando sangría de 1.25 cm. en el primer párrafo. Continúe el segundo párrafo.

Continúe el segundo párrafo

3.1 Primer subtítulo

En la actualidad, las unidades de información hacen frente a muchos cambios debido a los avances tecnológicos, explosión informativa, nuevos recursos y soportes, por lo cual se implementan servicios innovadores que les permitan a sus usuarios tener acceso a muchas fuentes de información. Para asegurar el acceso y uso de los servicios los usuarios requieren poseer una serie de habilidades que les permitan identificar, recuperar, manejar, discernir, organizar, utilizar y comunicar la información de manera eficaz para la toma de decisiones.

Entre las causas se pueden considerar la falta de tiempo asignado al taller, las limitaciones en cuanto a laboratorios, el poco personal, la falta de una correcta selección de los contenidos, así como, una calificación que asegure el cumplimiento de los objetivos.

CAPÍTULO IV

MARCO METODOLÓGICO

El presente capítulo describe el diseño metodológico utilizado para evaluar funciones de comparación entre distribuciones de grafos sometidas a perturbaciones estructurales controladas.

La investigación parte de una premisa central: una función de comparación entre distribuciones de grafos no debe evaluarse únicamente por el valor escalar que produce, sino por el tipo de estructura que representa, la forma en que responde ante perturbaciones conocidas, la estabilidad de esa respuesta y el costo computacional requerido. Por ello, el estudio compara workflows completos de evaluación, entendidos como la combinación de una representación de grafo, una regla de comparación y un conjunto de criterios de análisis.

La metodología se organiza en torno a una trayectoria experimental controlada. A partir de una distribución base de grafos, se generan versiones perturbadas mediante operadores estructurales parametrizados por una intensidad α . Posteriormente, cada workflow transforma los grafos en representaciones comparables y produce puntajes de discrepancia en distintos niveles de medición. La interpretación de los resultados considera sensibilidad, detectabilidad pareada, monotonía como criterio de consistencia, robustez, interpretabilidad y costo computacional.

4.1 Diseño general de la investigación

La investigación es de tipo experimental, comparativa y cuantitativa. Es experimental porque introduce perturbaciones estructurales controladas sobre colecciones de grafos; es comparativa porque contrasta familias metodológicas distintas; y es cuantitativa porque los resultados se expresan mediante puntajes de discrepancia, correlaciones, pruebas estadísticas, medidas de estabilidad y tiempos de ejecución.

Sea $\mathcal{D}$ una muestra empírica de grafos de referencia:

$$\mathcal{D} = \{G_1, G_2, \dots, G_n\}.$$

Para cada grafo G_i se genera una versión perturbada G_i^α mediante un operador T_α , donde α representa la intensidad de perturbación. La muestra perturbada se define como:

$$\mathcal{D}_\alpha = \{G_1^\alpha, G_2^\alpha, \dots, G_n^\alpha\}.$$

El objetivo metodológico es evaluar cómo distintos workflows estiman la discrepancia entre $\mathcal{D}$ y $\mathcal{D}_\alpha$. Cada workflow se compone de dos elementos principales: una representación estructural $\phi(G)$ y una función de comparación F . En términos generales, el puntaje de discrepancia puede expresarse como:

$$S_\alpha = F(\{\phi(G_i)\}_{i=1}^n, \{\phi(G_i^\alpha)\}_{i=1}^n).$$

Esta formulación permite separar dos decisiones metodológicas. La primera es qué información estructural se conserva mediante $\phi(G)$; la segunda es cómo se

comparan las representaciones resultantes mediante F . Esta separación es importante porque una función de comparación puede fallar no solo por la distancia utilizada, sino también porque la representación elegida no captura la estructura afectada por la perturbación.




FIGURA 4.1: Pipeline metodológico para la evaluación de funciones de comparación entre distribuciones de grafos bajo perturbaciones controladas.

El pipeline muestra que la unidad de análisis es el comportamiento del workflow completo frente a una trayectoria de perturbaciones.

4.2 Pregunta metodológica

La pregunta que orienta el diseño experimental es la siguiente:

¿Cómo evaluar, de forma rigurosa y comparable, qué workflows de comparación detectan cambios locales, mesoscópicos, globales, mixtos o distribucionales en muestras de grafos perturbadas?

Esta pregunta exige una evaluación que vaya más allá de un único puntaje final. Un valor escalar puede indicar que dos muestras de grafos difieren, pero no necesariamente explica qué tipo de diferencia fue detectada, si el cambio es consistente

a nivel pareado, si la respuesta se mantiene entre semillas, si el método responde ante intensidades bajas o si el costo computacional es viable.

Por esta razón, el diseño metodológico combina cuatro niveles de medición: discrepancia distribucional, cambio promedio de representación, distancia pareada individual y distancia pareada agregada. Estos niveles permiten distinguir entre separación global de muestras, desplazamiento del centro de la representación y consistencia del cambio en cada par original–perturbado.

4.3 Selección de workflows de comparación

El estudio no pretende evaluar todas las métricas existentes para comparar grafos. Una comparación exhaustiva produciría un diseño difícil de controlar y no necesariamente más informativo. En su lugar, se adopta una selección por familias metodológicas. Cada familia representa una forma distinta de codificar y comparar estructura.

Los workflows se seleccionan siguiendo cinco criterios:

1. **Pertinencia teórica:** el método debe estar conectado con las familias discutidas en el marco teórico.
2. **Escala estructural identificable:** el método debe asociarse razonablemente a información local, mesoscópica, global o multiescala.
3. **Viabilidad computacional:** el método debe poder ejecutarse repetidamente bajo distintas perturbaciones, intensidades y semillas.
4. **Interpretabilidad:** el resultado debe permitir alguna lectura estructural, aunque sea parcial.

5. **Reproducibilidad:** el método debe permitir registrar parámetros, semillas, configuraciones y versiones de implementación.

Con base en estos criterios, se consideran los siguientes workflows principales:

1. **GraphStats + MMD:** compara distribuciones de grafos a partir de descriptores estructurales y Maximum Mean Discrepancy.
2. **WLFeatures + MMD:** compara distribuciones de representaciones derivadas de Weisfeiler–Lehman mediante MMD.
3. **NetLSD:** compara firmas espectrales basadas en trazas del heat kernel.
4. **Diversity Curve Distance:** compara curvas de diversidad estructural obtenidas mediante una representación multiescala.

Esta selección permite cubrir familias con énfasis distintos. GraphStats + MMD funciona como línea base interpretable. WLFeatures + MMD representa sensibilidad a vecindarios y subestructuras. NetLSD representa una firma espectral global y multiescala. Diversity Curve Distance representa un enfoque basado en evolución de diversidad estructural bajo distintos niveles de resolución.

Es importante mencionar que en resultados preliminares los workflows se reportan con los identificadores de implementación correspondientes: la firma espectral se denomina **NativeNetLSD**, en referencia a una implementación fiel a la formulación original de NetLSD basada en la traza del *heat kernel*, y el enfoque multiescala se denomina **DiversityCurveDistance**. Ambos nombres designan los mismos métodos descritos en esta sección.

4.4 Datasets y distribuciones base

La evaluación utiliza dos tipos de datos: distribuciones sintéticas controladas y datasets reales. La etapa sintética prioriza validez interna, porque permite conocer el mecanismo generador y la perturbación aplicada. La etapa con datos reales permite evaluar si los patrones observados se mantienen en contextos menos idealizados.

4.4.1 Distribuciones sintéticas

Las distribuciones sintéticas se emplean para aislar propiedades estructurales específicas.

TABLA 4.1: Función metodológica de las distribuciones sintéticas consideradas.

Familia sintética		Propiedad controlada	Función en el experimento
Erdős–Rényi		Aleatoriedad homogénea y densidad	Caso base sin comunidades ni hubs explícitos.
Stochastic Block Model	Block	Comunidades generativas	Evaluar perturbaciones dependientes de comunidad con etiquetas estructurales conocidas.
Barabási–Albert		Hubs y grado heterogéneo	Evaluar sensibilidad ante modificación de nodos de alta conectividad.
Watts–Strogatz		Clustering y mundo pequeño	Evaluar cambios en cierre local y estructura de caminos.
Grid		Regularidad geométrica	Evaluar perturbaciones sobre conectividad local regular.
Lobster		Estructura arbórea ramificada	Evaluar cambios en ramas, hojas y caminos.

4.4.2 Dataset real

La etapa con datos reales utilizará el dataset **IMDB-BINARY**, perteneciente a la colección TUDataset [25]. Este dataset contiene grafos derivados de redes de colaboración entre actores, donde cada grafo representa una red ego asociada a una película y la tarea original consiste en clasificarla en una de dos categorías.

En esta tesis, IMDB-BINARY no se usará con fines de clasificación supervisada, sino como conjunto de grafos reales para evaluar funciones de comparación bajo

perturbaciones controladas. Su inclusión permite contrastar los patrones observados en distribuciones sintéticas con grafos empíricos que presentan variabilidad natural de tamaño y conectividad.

TABLA 4.2: Dataset real considerado en la evaluación.

Dataset	Dominio	Uso en la tesis
IMDB-BINARY	Redes de colaboración de actores	Evaluar si los workflows mantienen perfiles de sensibilidad en grafos reales con variabilidad estructural natural.

Si se incorporan datasets reales adicionales, deberán añadirse explícitamente en la Tabla 4.2, indicando dominio, número de grafos, tamaño aproximado, disponibilidad de etiquetas de nodos, disponibilidad de comunidades y justificación experimental. No se asumirán datasets reales no documentados.

4.5 Tratamiento de comunidades

Las perturbaciones dependientes de comunidad requieren distinguir entre comunidades generativas, comunidades observadas y comunidades inferidas.

En Stochastic Block Model, las comunidades forman parte del proceso generativo. Por tanto, las etiquetas de comunidad pueden tratarse como estructura conocida dentro del experimento sintético. En cambio, en datasets reales o en modelos sintéticos que no proporcionan etiquetas comunitarias, no se asumirá la existencia de comunidades ground truth.

Cuando un conjunto de grafos no proporcione etiquetas explícitas de comunidad a nivel de nodos, se utilizará un procedimiento auxiliar de detección de comunidades basado en maximización greedy de modularidad, siguiendo el algoritmo

de Clauset, Newman y Moore [13]. Esta decisión tiene una función operacional: obtener particiones estructurales aproximadas sobre las cuales aplicar perturbaciones controladas dependientes de comunidad.

Las comunidades inferidas mediante este procedimiento se tratarán como pseudo-etiquetas. No se interpretarán como comunidades reales ni como anotaciones semánticas del dominio original. Para cada experimento que dependa de estas particiones, se reportará:

1. el algoritmo utilizado para detectar comunidades;
2. los parámetros relevantes del algoritmo;
3. si el procedimiento es determinístico o depende de semilla;
4. el criterio de calidad de partición utilizado, cuando corresponda;
5. la forma en que las pseudo-etiquetas se emplean para aplicar la perturbación.

Si la partición inferida no muestra una relación estructural razonable con el grafo, los resultados asociados se interpretarán como exploratorios y no como evidencia concluyente sobre estructura comunitaria real.

4.6 Operadores de perturbación controlada

Las perturbaciones se diseñan como intervenciones estructurales parametrizadas por una intensidad α . La intensidad toma valores discretos:

$$\alpha \in \{0.0, 0.1, 0.2, \dots, 1.0\}.$$

Cuando $\alpha = 0$, la muestra perturbada debe ser equivalente a la muestra original. Cuando $\alpha = 1$, se aplica el nivel máximo de perturbación definido para el operador correspondiente. El significado exacto de α depende del operador: puede representar porcentaje de aristas modificadas, proporción de triángulos eliminados, intensidad de debilitamiento comunitario o pérdida de diversidad distribucional.

Las perturbaciones se clasifican según la escala estructural que afectan. Esta clasificación no pretende ser absoluta, ya que algunas perturbaciones locales pueden tener efectos globales. Su función es organizar la interpretación experimental.

4.6.1 Perturbaciones locales

Las perturbaciones locales modifican aristas, triángulos o vecindarios pequeños. Su objetivo es evaluar si los workflows capturan cambios de corto alcance.

1. **Inserción de aristas:** añade un porcentaje controlado de aristas ausentes.
2. **Eliminación de aristas:** elimina un porcentaje controlado de aristas existentes.
3. **Inserción de triángulos:** modifica la red para aumentar cierre triádico o clustering local.
4. **Eliminación de triángulos:** reduce estructuras triangulares preservando, en lo posible, otras propiedades.

Estas perturbaciones permiten evaluar si métodos como GraphStats + MMD o WLFeatures + MMD responden ante cambios directamente asociados a grados, clustering y vecindarios.

4.6.2 Perturbaciones mesoscópicas

Las perturbaciones mesoscópicas afectan estructuras intermedias, especialmente comunidades o bloques.

1. **Debilitamiento de comunidades:** reduce progresivamente la separación entre grupos, por ejemplo, disminuyendo conexiones intracomunidad o aumentando conexiones intercomunidad.
2. **Reasignación estructural parcial:** modifica la pertenencia de nodos a pseudo-comunidades cuando estas son inferidas, siempre reportando que no constituyen ground truth.

En SBM, estas perturbaciones se aplican sobre etiquetas generativas conocidas. En datasets sin etiquetas, se aplican sobre pseudo-etiquetas inferidas y sus conclusiones se interpretan con cautela.

4.6.3 Perturbaciones globales

Las perturbaciones globales afectan propiedades de conectividad general, hubs, caminos o estructura espectral.

1. **Modificación de hubs:** altera aristas incidentes a nodos de alta conectividad.
2. **Cambio de conectividad:** modifica la estructura de componentes o caminos entre regiones del grafo.
3. **Perturbación de caminos:** altera distancias de camino mínimo mediante inserciones, eliminaciones o recableados dirigidos.

Estas perturbaciones son especialmente relevantes para evaluar firmas espectrales y métodos multiescala, aunque también pueden afectar estadísticas locales.

4.6.4 Perturbaciones mixtas

Las perturbaciones mixtas combinan efectos locales y globales. El caso principal es el rewiring preservando grado.

1. **Rewiring preservando grado:** modifica la organización de las aristas manteniendo, en lo posible, la secuencia de grados.

Esta perturbación es metodológicamente importante porque separa la distribución de grados de otras propiedades estructurales. Si una métrica depende fuertemente del grado, podría subestimar cambios producidos por este operador.

4.6.5 Perturbaciones distribucionales

Las perturbaciones distribucionales modifican la composición de la muestra, no necesariamente cada grafo individual.

1. **Colapso distribucional:** reduce la diversidad de la muestra eliminando o subrepresentando ciertos modos estructurales.

Esta perturbación permite evaluar si una función de comparación detecta pérdida de cobertura distribucional. Es relevante en contextos de evaluación generativa, donde un conjunto de grafos puede parecer plausible individualmente, pero no representar adecuadamente toda la distribución original.

4.7 Protocolo experimental

El protocolo experimental se aplica de forma uniforme a cada combinación de dataset, perturbación, intensidad y workflow. La secuencia general es la siguiente:

1. Seleccionar una distribución base o dataset de grafos $\mathcal{D}$.
2. Definir el operador de perturbación T_α y su interpretación para cada valor de α .
3. Generar muestras perturbadas $\mathcal{D}_\alpha$ para cada intensidad.
4. Preservar la correspondencia pareada entre cada grafo original G_i y su versión perturbada G_i^α cuando el operador lo permita.
5. Extraer representaciones $\phi(G)$ para cada workflow.
6. Calcular puntajes distribucionales, cambios de media y distancias pareadas.
7. Evaluar sensibilidad, detectabilidad pareada, monotonicidad, robustez, costo computacional e interpretabilidad.
8. Registrar semillas, parámetros, tiempos de ejecución y configuración experimental.

El protocolo puede resumirse como:

$$\mathcal{D} \rightarrow \mathcal{D}_\alpha \rightarrow \Phi(\mathcal{D}), \Phi(\mathcal{D}_\alpha) \rightarrow S_\alpha, M_\alpha, p_{i,\alpha}, P_\alpha \rightarrow \text{criterios de evaluación.}$$

Esta formulación evita reducir la evaluación a un único número. El mismo workflow puede mostrar alta separación distribucional, pero baja consistencia pareada; o puede detectar cambios pareados sin producir una gran diferencia agregada entre distribuciones.

4.8 Niveles de medición y criterios de evaluación

Para simplificar la organización del capítulo, los niveles de medición y los criterios de evaluación se presentan de manera integrada. Primero se definen los puntajes calculados; luego se explica cómo se interpretan.

4.8.1 Discrepancia distribucional

La discrepancia distribucional evalúa si la muestra original y la muestra perturbada son distinguibles bajo un workflow determinado. Se define como:

$$S_\alpha = F(\Phi(\mathcal{D}), \Phi(\mathcal{D}_\alpha)),$$

donde:

$$\Phi(\mathcal{D}) = \{\phi(G_i)\}_{i=1}^n, \quad \Phi(\mathcal{D}_\alpha) = \{\phi(G_i^\alpha)\}_{i=1}^n.$$

Este nivel responde la pregunta general: si se observan dos muestras de grafos, ¿el workflow puede distinguirlas?

4.8.2 Cambio promedio de representación

El cambio promedio de representación evalúa si el centro de la representación se desplaza como consecuencia de la perturbación. Se define como:

$$M_\alpha = d\left(\overline{\Phi(\mathcal{D})}, \overline{\Phi(\mathcal{D}_\alpha)}\right).$$

Esta medida permite observar desplazamientos agregados. Sin embargo, se interpreta con cautela porque dos distribuciones pueden tener medias similares y diferir en varianza, dispersión, multimodalidad o estructura interna.

Conviene precisar que S_α y M_α no son necesariamente independientes: su relación depende de cómo cada workflow agrega las representaciones. En los workflows cuya regla de comparación F opera directamente como una distancia entre representaciones promedio como las firmas espectrales y las curvas multiescala evaluadas en esta tesis la discrepancia distribucional y el cambio de media coinciden por construcción, es decir, $S_\alpha = M_\alpha$. En cambio, en los workflows basados en Maximum Mean Discrepancy, S_α es un estadístico de dos muestras que incorpora momentos de orden superior a través del kernel, por lo que aporta información distinta de M_α . En consecuencia, los cuatro niveles de medición no deben leerse siempre como cuatro fuentes de evidencia independientes: para los métodos basados en promedios, el nivel distribucional y el de cambio de media constituyen una única señal. Esta distinción se retoma al interpretar los resultados.

4.8.3 Distancia pareada individual

La distancia pareada individual aprovecha la correspondencia entre cada grafo original y su versión perturbada:

$$p_{i,\alpha} = d(\phi(G_i), \phi(G_i^\alpha)).$$

Este nivel es central en la tesis porque evita depender exclusivamente de promedios. Permite evaluar si el cambio estructural introducido por T_α es capturado en la trayectoria individual de cada grafo, y constituye la base de las correlaciones por trayectoria ρ_i y de las pruebas estadísticas pareadas descritas más adelante.

Debe señalarse que el aprovechamiento pleno de este nivel exige persistir las distancias $p_{i,\alpha}$ de cada grafo, no solo su promedio por celda. Esta persistencia granular es precisamente la contribución central que el diseño metodológico habilita, y su ejecución completa se aborda en la fase posterior del trabajo; la etapa preliminar reportada en el Capítulo V registra la forma agregada P_α y sienta las bases para el análisis individual.

4.8.4 Distancia pareada agregada

La distancia pareada agregada resume las distancias individuales:

$$P_\alpha = \frac{1}{n} \sum_{i=1}^n p_{i,\alpha}.$$

Este puntaje permite comparar tendencias globales manteniendo la lógica pareada del diseño experimental. También se reportará la dispersión de $p_{i,\alpha}$ para evitar que el promedio oculte comportamientos heterogéneos.

4.8.5 Sensibilidad

La sensibilidad evalúa si el workflow responde ante incrementos de la perturbación. Conceptualmente, no se reduce al crecimiento monotónico del puntaje, sino que abarca tres componentes: la capacidad de detectar cambios desde intensidades bajas (velocidad o umbral de detección), la capacidad de diferenciar tipos de perturbación, y la coherencia de la respuesta con la escala estructural afectada.

Es importante distinguir entre esta noción amplia de sensibilidad y su operacionalización en cada etapa del trabajo. En esta etapa, la sensibilidad se estima mediante la correlación ordinal entre α y el puntaje (Sección 4.8.6), que captura

la componente de consistencia direccional pero no la velocidad ni el umbral de detección. La componente de velocidad requiere una métrica explícita de umbral y la componente de diferenciación fina requiere el análisis pareado a nivel individual; ambas dependen de la persistencia de las distancias $p_{i,\alpha}$ por grafo y se incorporan como objetivo de la fase posterior del trabajo. Por tanto, cuando en los resultados preliminares se reporte una “sensibilidad” cuantitativa, debe entenderse como la componente de consistencia direccional, no como la noción amplia completa.

Se analizará mediante curvas de S_α , M_α y P_α , además de distribuciones de $p_{i,\alpha}$ por nivel de perturbación cuando estas se encuentren disponibles.

4.8.6 Correlación entre intensidad y puntaje

La relación entre intensidad de perturbación y puntaje se evaluará mediante Spearman- ρ y Kendall- τ . Para el nivel distribucional:

$$\rho_S = \text{Spearman}((\alpha_0, \dots, \alpha_k), (S_{\alpha_0}, \dots, S_{\alpha_k})).$$

Para el nivel pareado agregado:

$$\rho_P = \text{Spearman}((\alpha_0, \dots, \alpha_k), (P_{\alpha_0}, \dots, P_{\alpha_k})).$$

Además, cuando sea posible, se calculará una correlación por trayectoria individual:

$$\rho_i = \text{Spearman}((\alpha_0, \dots, \alpha_k), (p_{i,\alpha_0}, \dots, p_{i,\alpha_k})).$$

La distribución de los valores ρ_i permitirá evaluar si la relación entre perturbación y distancia se mantiene a nivel granular o si solo aparece después de agregar los resultados.

4.8.7 Monotonicidad como criterio de consistencia

La monotonicidad se interpreta como un criterio complementario de consistencia, no como el aporte central de la tesis. Una respuesta monotónica indica que el puntaje tiende a aumentar conforme aumenta α , pero este comportamiento puede ser esperable en curvas agregadas.

Se utilizará la tasa de violaciones monotónicas:

$$v = \frac{\#\{j : S_{\alpha_{j+1}} < S_{\alpha_j}\}}{k - 1}.$$

Un valor bajo de v indica una respuesta ordenada. Sin embargo, una métrica no será considerada superior únicamente por tener menor v . La interpretación debe complementarse con sensibilidad, análisis pareado, robustez y costo computacional.

4.8.8 Pruebas estadísticas sobre diferencias pareadas

Para evaluar si los cambios entre niveles de perturbación son estadísticamente distinguibles, se aplicarán pruebas sobre diferencias pareadas cuando corresponda.

Para dos niveles consecutivos α_j y α_{j+1} , se comparan las distancias individuales:

$$\{p_{i,\alpha_j}\}_{i=1}^n \quad \text{y} \quad \{p_{i,\alpha_{j+1}}\}_{i=1}^n.$$

Si las diferencias pareadas presentan normalidad aproximada, se utilizará una prueba t pareada. Si no se desea asumir normalidad, se utilizará la prueba de rangos con signo de Wilcoxon. Cuando se realicen múltiples comparaciones entre niveles, perturbaciones o workflows, se aplicará una corrección por comparaciones múltiples, como Benjamini–Hochberg.

Estas pruebas no sustituyen el análisis estructural. Su función es evitar conclusiones basadas únicamente en inspección visual de curvas.

4.8.9 Robustez

La robustez evalúa la estabilidad de los resultados ante semillas y repeticiones experimentales. Para cada configuración se registrarán múltiples ejecuciones cuando sea computacionalmente viable. Se reportarán medidas como media, desviación estándar y coeficiente de variación:

$$CV = \frac{\sigma}{\mu}.$$

Una métrica sensible pero altamente inestable debe interpretarse con cautela. La robustez permite distinguir respuestas reproducibles de fluctuaciones dependientes de semillas.

4.8.10 Costo computacional

El costo computacional se evaluará registrando tiempo de ejecución y, cuando sea posible, memoria aproximada. El análisis considerará el tamaño de la muestra $|\mathcal{D}|$, el número de nodos $|V|$, el número de aristas $|E|$ y los parámetros internos de cada workflow.

El objetivo no es solo identificar qué método produce mayor discrepancia, sino determinar si dicha respuesta es viable bajo restricciones computacionales razonables. Para ello es muy importante, implementar fielmente los workflows, debido a que no se desea un análisis sesgado por el no uso de optimizaciones al momento de calcularlas.

4.8.11 Interpretabilidad y análisis de casos discordantes

La interpretabilidad evalúa si el resultado puede relacionarse con propiedades estructurales comprensibles. Por ejemplo, un aumento en GraphStats + MMD puede vincularse con cambios en grados, clustering o componentes; una respuesta de NetLSD puede interpretarse en términos de conectividad y difusión; una respuesta de WL puede asociarse con cambios de vecindario o subestructuras.

Además, se realizará un análisis de casos discordantes o atípicos. Se revisarán especialmente configuraciones donde:

1. una métrica responde con fuerza ante una perturbación donde se esperaba baja sensibilidad;
2. una métrica no responde ante una perturbación donde se esperaba sensibilidad alta;
3. las curvas agregadas sugieren monotonía, pero el análisis pareado muestra alta variabilidad;
4. WL o GraphStats detectan comportamientos que no aparecen en métricas espectrales;
5. NetLSD o Diversity Curves detectan cambios no capturados por descriptores simples.

Este análisis es importante porque los resultados más informativos no siempre son los esperados. Los casos raros pueden revelar limitaciones del diseño, errores de implementación, sensibilidad no prevista o propiedades estructurales no consideradas inicialmente.

4.9 Organización de resultados por tipo de perturbación

Los resultados se organizarán por tipo de perturbación, no únicamente por métrica. Esta decisión evita que la sección de resultados se convierta en una lista de métodos sin hilo conductor. Para cada perturbación se analizarán los mismos elementos:

1. Descripción objetiva del experimento
2. Workflows evaluados
3. Comportamiento de S_α
4. Comportamiento de P_α y $p_{i,\alpha}$
5. Correlación entre α y los puntajes de las distribuciones
6. Evidencia estadística, cuando corresponda
7. Interpretación según escala estructural afectada
8. Limitaciones del resultado.

Esta plantilla de análisis aplica de forma completa a las perturbaciones que preservan la correspondencia entre cada grafo original y su versión perturbada, esto es, las perturbaciones locales, mesoscópicas, globales y mixtas. Las perturbaciones distribucionales constituyen una excepción: al modificar la composición de la muestra

por ejemplo, mediante colapso de modos no inducen un emparejamiento uno a uno entre grafos, por lo que los niveles pareados $p_{i,\alpha}$ y P_α no están definidos en ese caso y su análisis se limita a la discrepancia distribucional S_α . Esta distinción se hace explícita para no atribuir a estas perturbaciones un tipo de evidencia que su diseño no permite generar.

El objetivo no será afirmar que una métrica es mejor de forma universal, sino caracterizar qué familia responde mejor bajo qué perturbación, con qué estabilidad y bajo qué costo.

4.10 Reproducibilidad

Para garantizar reproducibilidad, cada experimento deberá registrar:

1. Dataset o familia sintética utilizada
2. Número de grafos
3. Distribución de tamaños de grafos
4. Parámetros generativos del modelo sintético
5. Operador de perturbación
6. Valores de α
7. Número de semillas o repeticiones
8. Parámetros de cada workflow
9. Versión de librerías utilizadas
10. Tiempo de ejecución

11. Configuración de hardware, cuando sea relevante.

En el caso de datasets reales, se registrará también si existen etiquetas de clase, atributos de nodos, atributos de aristas o etiquetas comunitarias explícitas. Si se utilizan pseudo-etiquetas de comunidad, se reportará el método de inferencia correspondiente.

4.11 Limitaciones metodológicas

La metodología presenta varias limitaciones que deben considerarse al interpretar los resultados.

Primero, los resultados serán empíricos y dependerán de los modelos sintéticos, datasets, perturbaciones, parámetros e implementaciones utilizadas. Por tanto, las conclusiones no serán universales.

Segundo, los datasets sintéticos simplifican la complejidad de los grafos reales. Esta simplificación es necesaria para controlar el experimento, pero puede omitir patrones presentes en datos empíricos.

Tercero, los puntajes producidos por distintos workflows no siempre son comparables en magnitud absoluta. Por esta razón, el análisis se concentrará en tendencias, correlaciones, estabilidad, sensibilidad relativa y comportamiento por tipo de perturbación.

Cuarto, algunas perturbaciones pueden afectar más de una escala estructural. Por ejemplo, eliminar aristas es una operación local, pero puede alterar conectividad global si desconecta componentes. Por ello, la clasificación local, mesoscópica, global, mixta o distribucional se utilizará como guía interpretativa, no como división rígida.

Quinto, las comunidades inferidas mediante maximización de modularidad no serán tratadas como ground truth. Su uso se limita a operacionalizar perturbaciones dependientes de comunidad en grafos sin etiquetas explícitos.

Sexto, algunos workflows dependen de hiperparámetros relevantes, como número de iteraciones WL, escalas temporales de NetLSD, niveles de coarsening o ancho de banda del kernel MMD. Las conclusiones deberán restringirse a las configuraciones evaluadas.

4.12 Cierre del marco metodológico

El marco metodológico propuesto articula la comparación de distribuciones de grafos como un problema de representación, perturbación, medición e interpretación. Primero, se seleccionan distribuciones base sintéticas y reales. Luego, se aplican perturbaciones controladas con intensidad α . Posteriormente, distintos workflows transforman los grafos en representaciones estructurales y producen puntajes de discrepancia. Finalmente, los resultados se analizan mediante criterios de sensibilidad, detectabilidad pareada, monotonidad como control de consistencia, robustez, interpretabilidad y costo computacional.

Con esta organización, la tesis no se limita a verificar si las métricas aumentan cuando aumenta la perturbación. El objetivo es caracterizar perfiles de comportamiento: qué tipo de estructura detecta cada workflow, desde qué intensidad responde, qué tan estable es, qué costo computacional exige y en qué condiciones sus resultados son interpretables.

CAPÍTULO V

RESULTADOS PRELIMINARES

5.1 Descripción general del experimento preliminar

El objetivo de esta etapa no es establecer conclusiones definitivas sobre la superioridad de una familia de métricas, sino verificar si el protocolo experimental permite observar diferencias de comportamiento entre workflows de comparación de distribuciones de grafos bajo perturbaciones controladas.

La corrida consolidada contiene 20,328 registros experimentales. Estos registros corresponden a combinaciones de dataset, perturbación, intensidad α , semilla y workflow. La porción sintética contiene 19,008 filas, generadas a partir de tres familias de grafos con 24 semillas; la porción real contiene 1,320 filas correspondientes a IMDB-BINARY con 5 semillas. En todos los casos, se utilizaron once valores de intensidad:

$$\alpha \in \{0.0, 0.1, 0.2, \dots, 1.0\}.$$

Los datasets considerados en esta etapa fueron Erdős–Rényi, Stochastic Block Model, Barabási–Albert e IMDB-BINARY. Las familias sintéticas se ejecutaron con 100 grafos por semilla. Erdős–Rényi utilizó $n = 50$ y probabilidad de arista $p = 0.12$; Stochastic Block Model utilizó $n = 50$, cuatro bloques, $p_{\text{in}} = 0.28$ y $p_{\text{out}} = 0.04$; Barabási–Albert utilizó $n = 50$ y $m = 2$. En IMDB-BINARY se emplearon subconjuntos de 100 grafos por semilla, con tamaños variables entre 12 y 84 nodos.

Las perturbaciones evaluadas fueron inserción de aristas, eliminación de aristas, inserción de triángulos, eliminación de triángulos, debilitamiento de comunidades y modificación de hubs. Estas perturbaciones cubren cambios locales, mesoscópicos y globales. En esta etapa preliminar no se ejecutaron perturbaciones mixtas como rewiring preservando grado ni perturbaciones distribucionales como colapso de modos. Por tanto, cualquier conclusión sobre perturbaciones mixtas o distribucionales debe quedar pendiente.

Los workflows evaluados fueron:

1. **GraphStats + MMD**: MMD con kernel RBF sobre descriptores estructurales.
2. **WLFeatures + MMD**: MMD lineal sobre histogramas derivados de Weisfeiler–Lehman.
3. **NetLSD**: distancia L_2 entre firmas espectrales basadas en trazas de calor.
4. **Diversity Curve Distance**: distancia L_2 entre curvas de diversidad estructural basadas en caminos mínimos.

Aun no se cuenta todavía con resultados para Wasserstein–Weisfeiler–Lehman. Por ello, aunque esta familia fue considerada conceptualmente en el marco teórico, no son considerados como resultado experimental en esta sección.

Conviene delimitar desde el inicio el alcance de esta corrida. El análisis pareado se reporta únicamente en su forma agregada P_α , es decir, como promedio por celda de las distancias individuales $p_{i,\alpha}$; en esta etapa dichas distancias individuales no fueron persistidas por grafo. En consecuencia, el nivel granular las correlaciones por trayectoria ρ_i , las distribuciones de $p_{i,\alpha}$ y las pruebas estadísticas pareadas que constituye la contribución central de la tesis todavía no se ejecuta aquí, y se aborda

en la fase posterior del trabajo. Del mismo modo, la “sensibilidad” que se reporta corresponde a la correlación ordinal entre α y el puntaje, esto es, la componente de consistencia direccional definida en el marco metodológico, y no a la noción amplia que incorpora velocidad de detección y diferenciación fina por tipo de perturbación. Los resultados de esta etapa deben leerse, por tanto, como una validación del protocolo y una caracterización inicial de perfiles agregados, no como la evaluación granular definitiva.

5.2 Figuras utilizadas en el análisis preliminar

Para evitar una sección de resultados sobrecargada, se seleccionan únicamente las figuras que cumplen una función analítica directa. La Figura 5.1 resume la respuesta agregada de los workflows frente al incremento de α . La Figura 5.2 muestra la distancia pareada promedio. La Figura 5.3 permite comparar sensibilidad por granularidad estructural.

Las Figuras 5.1 y 5.2 presentan puntajes normalizados por workflow, de modo que comparan la *forma* de la respuesta a lo largo de α y no la magnitud absoluta entre workflows. Esta convención es necesaria porque los puntajes crudos de los cuatro métodos difieren en varios órdenes de magnitud (véase la Sección 5.3.1 y la Tabla 5.1); sin normalización, las curvas de los métodos de menor escala serían visualmente indistinguibles de una línea plana. La contrapartida es que la cercanía visual entre curvas normalizadas indica similitud de *perfil*, no equivalencia de intensidad de respuesta, lo cual debe tenerse presente al leer estas figuras y el mapa de la Figura 5.3.




FIGURA 5.1: Puntaje *normalizado por workflow* de discrepancia distribucional en función de la intensidad de perturbación α . La figura compara la forma de la respuesta de cada workflow frente al incremento progresivo de perturbación; no representa magnitudes absolutas comparables entre workflows (véase la Tabla 5.1).





FIGURA 5.2: Distancia pareada *promedio* (P_α , normalizada por workflow) entre cada grafo original y su versión perturbada. Esta figura complementa el análisis agregado, ya que aprovecha la correspondencia inducida por el protocolo experimental; corresponde al promedio por celda y no a las distancias individuales $p_{i,\alpha}$.



Valores casi idénticos (=, recuadro punteado): local: WL+MMD, NetLSD, Diversity Curves ($\Delta \leq 0.03$; valores 0.98, 0.98, 0.98) | mesoscopic: WL+MMD, NetLSD, Diversity Curves ($\Delta \leq 0.03$; valores 0.87, 0.89, 0.88) | Promedio: WL+MMD, NetLSD, Diversity Curves ($\Delta \leq 0.03$; valores 0.88, 0.88, 0.88)

FIGURA 5.3: Mapa de sensibilidad por granularidad estructural, entendida aquí como la correlación ordinal entre α y el puntaje (consistencia direccional). La figura resume el comportamiento relativo de los workflows frente a perturbaciones locales, mesoscópicas y globales; la cercanía entre workflows indica similitud de rango y no de magnitud de respuesta.

5.3 Resultados agregados por workflow

5.3.1 Rango de respuesta frente a magnitud de respuesta

Antes de resumir el comportamiento cualitativo, conviene separar dos lecturas que las figuras normalizadas tienden a confundir: la *consistencia de rango* entre α y el puntaje, y la *magnitud absoluta* de la respuesta de cada workflow. Ambas son legítimas, pero responden preguntas distintas.

La correlación ordinal empleada para estimar sensibilidad es invariante a la escala: reordena los valores antes de correlacionarlos, de modo que un workflow puede alcanzar una correlación cercana a la unidad tanto si su puntaje crudo varía en unidades como si lo hace en decenas de miles. Esto explica por qué WLFeatures +

MMD, NativeNetLSD y DiversityCurveDistance aparecen con valores de sensibilidad casi idénticos en varias celdas de la Figura 5.3 pese a operar en escalas muy diferentes.

La Tabla 5.1 reporta el máximo del puntaje distribucional crudo de cada workflow en la corrida consolidada. Los valores difieren en aproximadamente cuatro órdenes de magnitud.

TABLA 5.1: Magnitud máxima del puntaje distribucional crudo por workflow en la corrida consolidada. Las magnitudes no son directamente comparables entre familias, ya que corresponden a construcciones distintas (un estadístico MMD frente a distancias L_2 entre representaciones); se reportan para evidenciar la escala de respuesta dentro de cada workflow, no para inducir un ordenamiento de superioridad.

Workflow	Máx. distribution_score
WLFeatures + MMD	10 739.38
DiversityCurveDistance	191.48
NativeNetLSD	10.68
GraphStats + MMD	1.87

De esta contraposición se desprende una observación que refuerza el hilo metodológico de la tesis: workflows que coinciden en el *ordenamiento* inducido por α pueden diferir drásticamente en la *intensidad* de su respuesta. Por consiguiente, ninguna afirmación comparativa de esta sección debe apoyarse en la magnitud cruda entre familias, y la similitud de rango observada en las figuras normalizadas no debe leerse como equivalencia de comportamiento.

5.3.2 Síntesis cualitativa

La Tabla 5.2 resume el comportamiento agregado de los cuatro workflows evaluados. Las etiquetas cualitativas provienen de la matriz final generada a partir de los resultados experimentales. Estas etiquetas no deben interpretarse como

propiedades universales de los métodos, sino como una síntesis operacional bajo la configuración experimental evaluada.

TABLA 5.2: Resumen comparativo de los workflows evaluados

Workflow		Sensibilidad	Monotonicidad	Pareado	Robustez	Eficiencia
GraphStats MMD	+	Media	Media	Alta	Alta	Baja
WLFeatures MMD	+	Alta	Muy alta	Muy alta	Muy alta	Muy alta
NativeNetLSD		Alta	Muy alta	Muy alta	Muy alta	Baja
DiversityCurve Distance		Alta	Muy alta	Muy alta	Alta	Baja

Los resultados agregados sugieren que WLFeatures + MMD presenta el perfil preliminar más equilibrado entre sensibilidad, monotonicidad, detectabilidad pareada, robustez y eficiencia. Sin embargo, esta observación debe formularse con cautela: no implica que WLFeatures + MMD sea universalmente superior, sino que bajo las perturbaciones y datasets evaluados mostró un comportamiento consistente y computacionalmente favorable.

NativeNetLSD y DiversityCurve Distance también muestran alta sensibilidad y alta detectabilidad pareada, pero con menor eficiencia relativa. Además, en estos dos workflows el puntaje distribucional y el cambio de media coinciden operacionalmente, ya que ambos se calculan como una distancia entre representaciones medias. Por esta razón, no debe interpretarse que existe evidencia independiente entre nivel distribucional y mean-shift para estos métodos.

GraphStats + MMD muestra un perfil más irregular. Aunque mantiene detectabilidad pareada alta, su sensibilidad y monotonicidad agregadas son más bajas que las de los otros workflows. Este resultado es metodológicamente importante porque muestra que una línea base interpretable puede detectar cambios a nivel pareado y, al mismo tiempo, producir respuestas distribucionales menos estables bajo ciertas perturbaciones.

5.4 Resultados en perturbaciones locales

Las perturbaciones locales evaluadas fueron inserción de aristas, eliminación de aristas, inserción de triángulos y eliminación de triángulos. En términos generales, la eliminación de aristas y la inserción de aristas fueron detectadas por la mayoría de workflows con sensibilidad alta. Sin embargo, se observó un caso discordante importante: GraphStats + MMD presentó baja sensibilidad distribucional en inserción de aristas para las familias sintéticas, mientras que su detectabilidad pareada se mantuvo alta.

Este comportamiento indica que el descriptor estructural utilizado por GraphStats sí registra cambios entre cada grafo original y su versión perturbada, pero la agregación mediante MMD con kernel RBF no produce una curva distribucional igualmente estable. Una posible explicación es que la elección fija del ancho de banda del kernel afecte la respuesta distribucional. No obstante, esta explicación debe tratarse como hipótesis de diagnóstico, porque los resultados actuales no contienen un análisis específico de sensibilidad al ancho de banda.

En las perturbaciones basadas en triángulos se observa un patrón similar. Para inserción de triángulos, GraphStats + MMD presenta sensibilidad negativa o cercana a cero en varias familias sintéticas, mientras que los otros workflows mantienen valores altos. Este caso es relevante porque los triángulos son una estructura que, en principio, debería ser visible para estadísticas estructurales. Por tanto, el resultado no debe interpretarse como una incapacidad directa de los descriptores, sino como una señal de que la combinación descriptor–kernel–parámetro puede producir comportamientos no monotónicos.

Estos resultados apoyan una conclusión preliminar: la monotonidad agregada no basta para evaluar un workflow. Es necesario contrastar el puntaje distribucional con el análisis pareado y revisar casos en los que ambos niveles producen

señales distintas.

5.5 Resultados en perturbaciones mesoscópicas

La perturbación mesoscópica evaluada fue el debilitamiento de comunidades. Esta perturbación requiere una interpretación cuidadosa porque no todas las comunidades tienen el mismo estatus metodológico.

En Stochastic Block Model, las comunidades corresponden a la partición generativa del modelo. Por tanto, el debilitamiento comunitario se aplica sobre etiquetas estructuralmente conocidas. En este escenario, los workflows muestran sensibilidad variable, con diferencias importantes entre métodos. Esto sugiere que la degradación de comunidades no es capturada de manera uniforme por todas las representaciones.

Conviene matizar el estatus de estas etiquetas a lo largo de la trayectoria de intensidad. Las etiquetas generativas describen la estructura de la muestra original; a medida que α crece, el operador debilita progresivamente esa estructura, de modo que en intensidades altas la partición de referencia deja de corresponder a una organización comunitaria efectivamente presente en el grafo perturbado. Por ello, la etiqueta “conocida” es un ancla válida del punto de partida y de la magnitud de la intervención aplicada, pero no debe leerse como una comunidad vigente en el extremo perturbado de la trayectoria.

En Erdős–Rényi, las comunidades utilizadas no son ground truth, sino particiones detectadas. En este caso, las sensibilidades son bajas y el mapa de fallas marca la configuración como inestable. Este resultado es coherente con la función de Erdős–Rényi como control negativo: al no existir comunidades generativas, una perturbación basada en comunidades detectadas no debería necesariamente producir una señal estructural fuerte.

En IMDB-BINARY, las comunidades también son detectadas, no anotaciones reales del dominio. Sin embargo, los resultados preliminares muestran sensibilidades más altas que en Erdős–Rényi. Esto puede indicar que las particiones detectadas capturan alguna organización estructural útil en las redes de coaparición. Aun así, esta interpretación debe mantenerse como operacional: las comunidades inferidas se tratan como pseudo-etiquetas, no como comunidades semánticas reales.

5.6 Resultados en perturbaciones globales

La perturbación global evaluada fue la modificación de hubs. Esta categoría produjo algunos de los comportamientos más débiles e inestables en las familias sintéticas. En Erdős–Rényi y Stochastic Block Model, varios workflows mostraron sensibilidades menores que en perturbaciones locales o mesoscópicas, y el mapa de fallas identificó configuraciones inestables.

Este resultado puede explicarse parcialmente por la naturaleza de los datasets. En Erdős–Rényi no existe una estructura de hubs marcada por construcción, por lo que modificar nodos de mayor grado puede no producir una señal global tan clara como en grafos con distribución de grado heterogénea.

Barabási–Albert cumple aquí el papel de control positivo para esta perturbación, ya que la presencia de hubs forma parte de su mecanismo generativo por conexión preferencial. Es por tanto el dataset donde la modificación de hubs debería producir la señal más informativa, y su comportamiento es el que permite discriminar si la debilidad observada en Erdős–Rényi y Stochastic Block Model responde a una limitación de los workflows o, más bien, a la ausencia de hubs sobre los cuales intervenir. En consecuencia, la lectura de la modificación de hubs debe anclarse en el resultado de Barabási–Albert antes que en el de las familias sin hubs: una respuesta clara en Barabási–Albert junto a respuestas débiles en Erdős–Rényi

y Stochastic Block Model sería coherente con un diseño válido en el que la señal aparece solo cuando existe la estructura pertinente; una respuesta igualmente débil en Barabási–Albert, en cambio, obligaría a revisar la implementación del operador o la representación empleada. Por tratarse de una etapa preliminar, esta comparación se reporta como diagnóstico y se contrasta explícitamente con el mapa de fallas antes de extraer conclusiones.

En IMDB-BINARY, la modificación de hubs muestra mayor estabilidad que en Erdős–Rényi y Stochastic Block Model. Esto sugiere que los nodos de alta conectividad en grafos reales de coaparición pueden tener un papel estructural más significativo. Sin embargo, esta interpretación sigue siendo preliminar y debe validarse con análisis adicional sobre distribución de grados, centralidad y efectos de la perturbación.

5.7 Perturbaciones no evaluadas en esta etapa

Aunque el marco metodológico considera perturbaciones mixtas y distribucionales, estas no fueron ejecutadas en la corrida preliminar analizada. En particular, no existen resultados para rewiring preservando grado, mode dropping ni colapso distribucional.

Esta ausencia debe explicitarse porque afecta el alcance de los resultados. Las conclusiones actuales solo cubren perturbaciones locales, mesoscópicas y una perturbación global basada en hubs. Por tanto, cualquier afirmación sobre robustez ante perturbaciones mixtas o pérdida de diversidad distribucional debe quedar como validación pendiente.

5.8 Relación con las hipótesis metodológicas

Los resultados preliminares apoyan parcialmente las hipótesis metodológicas de la tesis. En primer lugar, los métodos basados en Weisfeiler–Lehman muestran un comportamiento consistente frente a perturbaciones locales y de motivo, lo cual es compatible con su diseño basado en refinamiento de vecindarios. En segundo lugar, NetLSD y DiversityCurveDistance muestran sensibilidad alta en varias configuraciones, lo que sugiere que las representaciones espectrales y multiescala capturan cambios estructurales de manera estable en el protocolo evaluado.

Sin embargo, los resultados no permiten sostener todavía que una familia sea superior en sentido general. La evidencia muestra perfiles de comportamiento, no jerarquías universales. Por ejemplo, GraphStats + MMD es menos estable en algunos puntajes distribucionales, pero mantiene interpretabilidad alta y detectabilidad pareada alta. WLFeatures + MMD es eficiente y estable en esta corrida, pero no reemplaza necesariamente a métodos espectrales o multiescala cuando la interpretación requiere propiedades globales de difusión o diversidad estructural.

La hipótesis más fuerte que sí se refuerza es metodológica: el análisis agregado debe complementarse con análisis pareado y diagnóstico por perturbación. Los casos discordantes de GraphStats + MMD muestran que una curva distribucional puede ocultar o distorsionar señales que aparecen claramente en el nivel pareado.

5.9 Limitaciones de los resultados preliminares

Los resultados presentados tienen varias limitaciones.

Primero, la sensibilidad calculada corresponde a una correlación entre α y el puntaje, pero no mide directamente la velocidad de detección. Dos workflows pueden obtener alta sensibilidad aunque uno detecte cambios desde $\alpha = 0.1$ y otro

recién responda con claridad en intensidades mayores. Por ello, falta incorporar una métrica explícita de umbral o velocidad de detección.

Segundo, el análisis pareado actual se conserva únicamente como promedio por celda. No se han persistido las distancias individuales por grafo. Esto impide aplicar pruebas estadísticas pareadas a nivel de grafo, como t-test pareado o Wilcoxon signed-rank.

Tercero, queda pendiente el análisis en la memoria utilizada por los workflows. El criterio de costo computacional se limita por ahora al tiempo de ejecución.

Cuarto, GraphStats + MMD utiliza un ancho de banda RBF fijo. Dado que este workflow muestra comportamientos no monotónicos en algunas perturbaciones, es necesario realizar un análisis de sensibilidad respecto al ancho de banda antes de atribuir el comportamiento exclusivamente al tipo de descriptor estructural.

5.10 Validaciones pendientes

Antes de formular conclusiones definitivas, se requieren las siguientes validaciones:

1. Persistir las distancias pareadas individuales $p_{i,\alpha}$ para cada grafo y cada intensidad.
2. Aplicar pruebas estadísticas pareadas entre niveles de perturbación y entre workflows, usando t-test pareado o Wilcoxon según corresponda.
3. Incorporar corrección por múltiples comparaciones, por ejemplo Benjamini–Hochberg.
4. Definir una métrica de velocidad o umbral de detección para distinguir métodos que responden temprano de métodos que solo son monotónicos en el agregado.

5. Diagnosticar el efecto del ancho de banda fijo en GraphStats + MMD.
6. Ejecutar perturbaciones mixtas, especialmente rewiring preservando grado.
7. Ejecutar perturbaciones distribucionales, especialmente colapso de modos.

5.11 Síntesis preliminar

Los resultados preliminares muestran que el protocolo experimental es capaz de producir diferencias observables entre workflows de comparación de distribuciones de grafos. La evidencia no debe interpretarse como una demostración de superioridad universal de una métrica, sino como una caracterización inicial de perfiles de respuesta.

WLFeatures + MMD presenta el comportamiento preliminar más equilibrado en sensibilidad, detectabilidad pareada, robustez y eficiencia. NetLSD y Diversity-CurveDistance muestran respuestas estables y alta sensibilidad en varias configuraciones, aunque con mayor costo computacional relativo. GraphStats + MMD conserva alta interpretabilidad y detectabilidad pareada, pero exhibe comportamientos distribucionales no monotónicos en inserción de aristas e inserción de triángulos.

La conclusión metodológica más importante es que la monotonidad agregada no debe ser el centro del análisis. Los resultados más informativos surgen al contrastar sensibilidad agregada, distancia pareada, tipo de perturbación, estabilidad entre semillas y costo computacional. Esta lectura es coherente con el objetivo de la tesis: evaluar cómo distintas familias de funciones de comparación responden ante perturbaciones estructurales controladas, sin asumir que una de ellas es universalmente mejor.

CONCLUSIONES

Lorem ipsum dolor sit amet, dicant volutpat vulputate sea at. Et nam volumus voluptua, ea noster omnesque has. Qui ut graeci melius platonem. Sit fugit prompta dignissim cu. Soluta meliore repudiare vis in, eum id liber maiestatis contentiones.

Ea sit suas melius verear. Fugit facilisis at vel, apeirian appellantur ex nec. Vis id quis elit qualisque. Ludus sadipscing eu eum.

Ea inani insolens dissentiunt eos, wisi efficiendi ex vim, modus justo inani et pro. Eam at modus definiebas, id eos philosophia disputationi, eu qui facete habemus. In dico unum neglegentur mea, ne phaedrum disputationi his. Tibique deseruisse mel ne, latine aperiri phaedrum duo ex. Erant corrumpit ut duo, in erant possim reprehendunt nec. Aequae nonumes minimum te eam, possim constituto qui ei, in has suas quidam molestie.

Vel no intellegat voluptaria, ei sed causae scaevola comprehensam. No erant cetero dissentiet per, mei an nulla scaevola. Euismod delicata vis eu, in odio docendi persecuti sea. Eos fabellas accusata at. His eu reque altera sadipscing, id ius regione lobortis expetenda, minim timeam dignissim vix eu.

Unum dui definitiones vel in. Nulla dicit mei ea, odio nulla an pri. Cu docendi torquatos usu. Possit maiorum rationibus ea duo, eu vitae primis postulant sed, mel erat officiis principes an. Pro saepe regione volumus id, debet reformidans ex his. Sale altera moderatius duo ea, an fastidii volutpat per, et mel maiorum corpora.

Modo malis et eam. Veniam equidem mei ad, mucius facilisi et pro. Postea eripuit neglegentur vis no. Id vis quis eleifend appellantur, sit integre singulis ei.

RECOMENDACIONES

Lorem ipsum dolor sit amet, mei no laboramus gloriatur, no timeam euri-
pidis qui, eu eos aperiam patrioque accommodare. Mei probo accommodare an, ex
case minim salutatus sit. Ad doming impetus mei, placerat verterem has no. His
assum quaeque et, ea aliquid dissentiet eum. Copiosae evertitur cum te, sea clita
disputationi ea.

Libris ridens malorum cu vis. Per vitae eirmod cotidieque cu. Cum unum
mucius alterum eu, nam enim regione appellantur id. Cum putant dignissim te, est
dolore essent definiebas ei. Facilisi convenire vix in, dictas delenit et per. Pro tota
affert argumentum cu.

REFERENCIAS BIBLIOGRÁFICAS

- [1] J. You, R. Ying, X. Ren, W. L. Hamilton, and J. Leskovec, “GraphRNN: Generating realistic graphs with deep auto-regressive models,” in *Proceedings of the 35th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 80. PMLR, 2018, pp. 5708–5717.
- [2] A. Gretton, K. M. Borgwardt, M. J. Rasch, B. Schölkopf, and A. Smola, “A kernel two-sample test,” *Journal of Machine Learning Research*, vol. 13, pp. 723–773, 2012.
- [3] R. Thompson, B. Knyazev, E. Ghalebi, J. Kim, and G. W. Taylor, “On evaluation metrics for graph generative models,” in *International Conference on Learning Representations*, 2022.
- [4] F. R. K. Chung, *Spectral Graph Theory*, ser. CBMS Regional Conference Series in Mathematics. American Mathematical Society, 1997, vol. 92.
- [5] U. von Luxburg, “A tutorial on spectral clustering,” *Statistics and Computing*, vol. 17, no. 4, pp. 395–416, 2007.
- [6] A. Tsitsulin, D. Mottin, P. Karras, A. Bronstein, and E. Müller, “NetLSD: Hearing the shape of a graph,” in *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, ser. KDD ’18. Association for Computing Machinery, 2018, pp. 2347–2356.

- [7] N. Shervashidze, P. Schweitzer, E. J. van Leeuwen, K. Mehlhorn, and K. M. Borgwardt, “Weisfeiler–lehman graph kernels,” *Journal of Machine Learning Research*, vol. 12, pp. 2539–2561, 2011.
- [8] M. Togninalli, E. Ghisu, F. Llinares-López, B. Rieck, and K. Borgwardt, “Wasserstein weisfeiler–lehman graph kernels,” in *Advances in Neural Information Processing Systems*, vol. 32, 2019.
- [9] P. Erdős and A. Rényi, “On random graphs i,” *Publicationes Mathematicae Debrecen*, vol. 6, pp. 290–297, 1959.
- [10] P. W. Holland, K. B. Laskey, and S. Leinhardt, “Stochastic blockmodels: First steps,” *Social Networks*, vol. 5, no. 2, pp. 109–137, 1983.
- [11] A.-L. Barabási and R. Albert, “Emergence of scaling in random networks,” *Science*, vol. 286, no. 5439, pp. 509–512, 1999.
- [12] D. J. Watts and S. H. Strogatz, “Collective dynamics of ‘small-world’ networks,” *Nature*, vol. 393, no. 6684, pp. 440–442, 1998.
- [13] A. Clauset, M. E. J. Newman, and C. Moore, “Finding community structure in very large networks,” *Physical Review E*, vol. 70, no. 6, p. 066111, 2004.
- [14] P. Wills and F. G. Meyer, “Metrics for graph comparison: A practitioner’s guide,” *PLOS ONE*, vol. 15, no. 2, p. e0228728, 2020.
- [15] S. V. N. Vishwanathan, N. N. Schraudolph, R. Kondor, and K. M. Borgwardt, “Graph kernels,” *Journal of Machine Learning Research*, vol. 11, pp. 1201–1242, 2010.
- [16] M. E. J. Newman, *Networks: An Introduction*. Oxford University Press, 2010.
- [17] K. Limbeck, N. Häusermann, M. Carrasco, G. Wolf, and B. Rieck, “Diversity curves for graph representation learning,” 2026.

- [18] K. M. Borgwardt and H.-P. Kriegel, “Shortest-path kernels on graphs,” in *Proceedings of the Fifth IEEE International Conference on Data Mining*, ser. ICDM ’05. IEEE, 2005, pp. 74–81.
- [19] N. M. Kriege, F. D. Johansson, and C. Morris, “A survey on graph kernels,” *Applied Network Science*, vol. 5, no. 1, p. 6, 2020.
- [20] C. Villani, *Optimal Transport: Old and New*, ser. Grundlehren der mathematischen Wissenschaften. Springer, 2009, vol. 338.
- [21] G. Peyré and M. Cuturi, “Computational optimal transport,” *Foundations and Trends in Machine Learning*, vol. 11, no. 5–6, pp. 355–607, 2019.
- [22] Student, “The probable error of a mean,” *Biometrika*, vol. 6, no. 1, pp. 1–25, 1908.
- [23] F. Wilcoxon, “Individual comparisons by ranking methods,” *Biometrics Bulletin*, vol. 1, no. 6, pp. 80–83, 1945.
- [24] Y. Benjamini and Y. Hochberg, “Controlling the false discovery rate: A practical and powerful approach to multiple testing,” *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 57, no. 1, pp. 289–300, 1995.
- [25] C. Morris, N. M. Kriege, F. Bause, K. Kersting, P. Mutzel, and M. Neumann, “TUDataset: A collection of benchmark datasets for learning with graphs,” in *ICML 2020 Workshop on Graph Representation Learning and Beyond (GRL+ 2020)*, 2020.

ANEXOS

Los algoritmos desarrollados